

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104376-111119

**Autentifikácia emócií operátora na základe
výrazu tváre**

Diplomová práca

2025

Bc. Maroš Kocúr

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104376-111119

**Autentifikácia emócií operátora na základe
výrazu tváre**

Diplomová práca

Študijný program:	Robotika a kybernetika
Študijný odbor:	kybernetika
Školiace pracovisko:	Ústav robotiky a kybernetiky, FEI STU v Bratislave
Školitel:	prof. Ing. Jarmila Pavlovičová, PhD.
Konzultant:	Ing. Michal Tölggyessy, PhD.

2025

Bc. Maroš Kocúr



ZADANIE DIPLOMOVEJ PRÁCE

Študent: **Bc. Maroš Kocúr**

ID študenta: 111119

Študijný program: robotika a kybernetika

Študijný odbor: kybernetika

Vedúci práce: Ing. Michal Tölgessy, PhD.

Vedúci pracoviska: prof. Ing. František Duchoň, PhD.

Miesto vypracovania: Ústav robotiky a kybernetiky

Názov práce: **Autentifikácia emócií operátora na základe výrazu tváre**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

Pri interakcii človeka s robotickým systémom je dôležité, aby robot vedel aj to, v akom emočnom rozpoložení sa operátor nachádza. Cieľom práce je vytvoriť modul, ktorý robotu takúto informáciu poskytne. Predpokladá sa využitie RGB kamery, ale je možnosť využiť aj RGB-D kamery.

Úlohy práce:

1. Analyzujte existujúce metódy analýzy emócií na základe výrazu tváre.
2. Naštudujte princípy tvorby biometrických modelov tváre a metódy detektie a rozpoznávania tváre.
3. Navrhnite a implementujte systém pre identifikáciu emócií operátora na základe jeho tváre.
4. Testujte a validujte systém na simulovaných aj reálnych dátach.
6. Vytvorte ROS2 balík pre daný systém.
7. Vyhodnoťte experimenty a dosiahnuté výsledky.

Termín odovzdania diplomovej práce: 16. 05. 2025

Dátum schválenia zadania diplomovej práce: 16. 10. 2024

Zadanie diplomovej práce schválil: prof. Ing. Jarmila Pavlovičová, PhD. – garantka študijného programu

Podakovanie

Na tomto mieste by som sa rád podakoval svojmu školiteľovi Ing. Michalovi Tölgyessymu, PhD. za odborné vedenie, cenné rady a podporu počas celej doby riešenia diplomovej práce. Podakovanie patrí aj Ústavu robotiky a kybernetiky FEI STU za vytvorenie kvalitného výskumného prostredia a možnosť pracovať na tejto téme v rámci moderného robotického pracoviska.

Abstrakt

Interakcia človeka s robotom v dynamickom prostredí si čoraz viac vyžaduje pochopenie emocionálneho stavu operátora s cieľom optimalizovať komunikáciu a rozhodovacie procesy. Cieľom tejto práce je navrhnúť a implementovať modul, ktorý poskytuje robotickému systému emocionálnu spätnú väzbu a umožňuje mu zisťovať výrazy tváre operátora a odvodzovať jeho emocionálne stavy. S využitím kamery RGB s možnosťou integrácie kamery RGB-D bude systém využívať biometrické modely tváre a techniky rozpoznávania tváre na identifikáciu emócií v reálnom čase. Medzi klúčové úlohy patrí analýza súčasných metód detektie emócií výrazu tváre, štúdium princípov tvorby biometrických modelov tváre a implementácia robustného systému na detekciu emócií. Systém bude overený prostredníctvom testovania na simulovaných aj reálnych súboroch údajov. Okrem toho bude vyvinutý balík ROS2, ktorý zabezpečí bezproblémovú integráciu v rámci robotických systémov. Výsledky budú kriticky posúdené prostredníctvom experimentov s cieľom zabezpečiť presnosť a efektívnosť výkonu v reálnych aplikáciách.

Klúčové slová

RGB kamera, neurónová siet, ROS, autentifikácia, emócie, výrazy tváre

Abstract

Human-robot interaction in dynamic environments increasingly requires an understanding of the operator's emotional state to optimize communication and decision-making processes. This work aims to design and implement a module that provides emotional feedback to a robotic system, enabling it to detect the operator's facial expressions and infer emotional states. Leveraging an RGB camera, with the option to integrate an RGB-D camera, the system will employ biometric facial models and facial recognition techniques to identify emotions in real-time. Key tasks include analyzing current facial expression emotion detection methods, studying the principles of facial biometric model creation, and implementing a robust system for emotion detection. The system will be validated through testing on both simulated and real datasets. Additionally, a ROS2 package will be developed to ensure seamless integration within robotic systems. The outcomes will be critically assessed through experiments to ensure accuracy and performance efficiency in real-world applications.

Keywords

RGB camera, neural network, ROS, authentication, emotions, facial expressions

Obsah

Úvod	12
1 Úvod	13
1.1 Motívacia	14
1.2 Ciele práce	15
2 Teoretické základy	18
2.1 Emócie a ich prejav	18
2.1.1 Kultúrne rozdiely v prejave emócií	18
2.1.2 Výrazy tváre ako indikátory emócií	19
2.2 Analýza obrazu	19
2.2.1 Detekcia tváre	20
2.2.2 Extraktcia príznakov	21
2.2.3 Klasifikácia	21
2.3 Biometria	22
2.3.1 Princípy biometrických systémov	22
2.3.2 Identifikácia vs. verifikácia	23
2.3.3 Výhody a výzvy biometrie tváre	23
3 Existujúce metody analýzy emócií	25
3.1 Ručné značenie	25
3.2 Automatická analýza emócií	25
3.2.1 Konvolučné neurónové siete	26
3.2.2 Typy vhodných neurónových sietí	26
3.2.3 Príklady použitia počítačového videnia	26
4 Návrh riešenia	28
4.1 Porovnanie vybraných metód	28
4.2 Architektúra systému ResEmoteNet	29
4.2.1 Hlavné komponenty architektúry	29
4.2.2 Prínosy architektúry ResEmoteNet	30
4.2.3 Experimentálne výsledky	30
4.2.4 Schéma architektúry systému	30
4.3 Výber dát	32
4.3.1 Dôvody výberu RAF-DB	32
4.3.2 Porovnanie s inými datasetmi	32
4.3.3 Prínos pre prácu	32

4.3.4	Príprava dát	33
4.4	Extrakcia príznakov	33
4.4.1	Metódy extrakcie príznakov	33
4.4.2	Porovnanie metód	34
4.4.3	Integrácia príznakov v ResEmoteNet	34
4.4.4	Experimentálne výsledky	35
4.5	Klasifikácia	35
4.5.1	Metódy klasifikácie	35
4.5.2	Porovnanie metód klasifikácie	36
4.5.3	Implementácia klasifikátora v systéme ResEmoteNet	36
4.6	Výber hyperparametrov	36
4.6.1	Klúčové hyperparametre a ich úloha	37
4.6.2	Porovnanie vplyvu hyperparametrov	37
4.6.3	Optimalizačné stratégie	38
4.6.4	Augmentačné parametre	38
4.6.5	Záver	38
4.7	Integrácia do robotického pracoviska COCOHRIP	38
5	Implementácia riešenia	40
5.1	Vývojové prostredie a infraštruktúra	40
5.2	Trénovanie modelu ResEmoteNet	40
5.2.1	Organizácia vývojového prostredia	40
5.2.2	Načítavanie a príprava dát	40
5.2.3	Augmentácia dát	40
5.2.4	Architektúra modelu	41
5.2.5	Trénovací proces	41
5.2.6	Ukladanie checkpointov	41
5.2.7	Vizualizácia výsledkov	41
5.2.8	Optimalizačné výzvy	42
5.3	Integrácia do ROS2 ekosystému	42
5.4	Webová vizualizácia pomocou Flask	43
5.5	Validácia na robotickom pracovisku COCOHRIP	43
5.6	Výsledky klasifikácie na datasete RAF-DB	43
6	Experimentsy a vyhodnotenie	45
6.1	Úvod	45
6.2	Testovanie na reálnych dátach	45
6.2.1	Priebeh testovania	45

6.2.2	Problémové emócie: strach a smútok	46
6.2.3	Pozorovania	46
6.2.4	Zhrnutie	46
6.3	Dotazníkový experiment s ľuďmi	46
6.3.1	Zber a spracovanie odpovedí	47
6.3.2	Najčastejšie chyby ľudí	47
6.3.3	Porovnanie s modelom	47
6.4	Vizualizácia výsledkov	47
6.4.1	Zhrnutie	48
6.5	Testovanie s rôznymi zariadeniami a podmienkami	48
6.5.1	Výsledky na rôznych zariadeniach	48
6.5.2	Vplyv svetelných podmienok	49
6.5.3	Zhrnutie	49
6.6	Porovnanie s výsledkami modelu	49
6.7	Analýza výsledkov	50
6.8	Zhrnutie experimentov	50
6.8.1	Silné stránky systému	50
6.8.2	Slabé stránky systému	51
6.8.3	Odporučané metodológie a nástroje pre ďalší výskum	51
7	Záver	52
7.1	Zhodnotenie práce	52
7.2	Obmedzenia práce	52
7.3	Budúce smerovanie	53
Záver	54	
Literatúra	55	
Použitie nástrojov umelej inteligencie	56	
A Zdrojový kód pre rozpoznávanie emócií	57	
B Zdrojový kód C++	66	
C Zdrojový kód pre streamovanie snímok z kamier	68	
D Zdrojový kód pre trenovanie modelu	70	
E Zdrojový kód pre Docker	75	

F Používateľský manuál	78
F.1 Návod na trénovanie modelu	78
F.1.1 Požiadavky	78
F.1.2 Postup trénovania	78
F.2 Návod na testovanie s ROS2	79
F.2.1 Požiadavky	79
F.2.2 Inštalácia a zostavenie	79
F.2.3 Spustenie systému	80
F.2.4 Riešenie problémov	81
F.2.5 Ukončenie systému	81

Zoznam značiek a skratiek

CNN	Convolutional neural network, v slovenčine <i>konvolučná neurónová siet</i>
DCNN	Deep convolutional neural network, v slovenčine <i>hlboká konvolučná neurónová siet</i>
LSTM	Long short-term memory, v slovenčine <i>dlhodobá krátkodobá pamäť</i>
RNN	Recurrent neural network, v slovenčine <i>rekurentná neurónová siet</i>
ROS	Robot Operating system, v slovenčine <i>robotický operačný systém</i>

Zoznam výpisov kódov

1	Python skript pre rozpoznávanie emócií	57
2	Implementácia rozpoznávania emócií v C++	66
3	CMakeLists.txt pre projekt rozpoznávania emócií	66
4	Python publisher snímok z kamier	68
5	Python skript použitý na trenovanie modelu	70
6	Dockerfile pre rozpoznávanie emócií	75
7	docker-compose.yml pre systém rozpoznávania emócií	76

Úvod

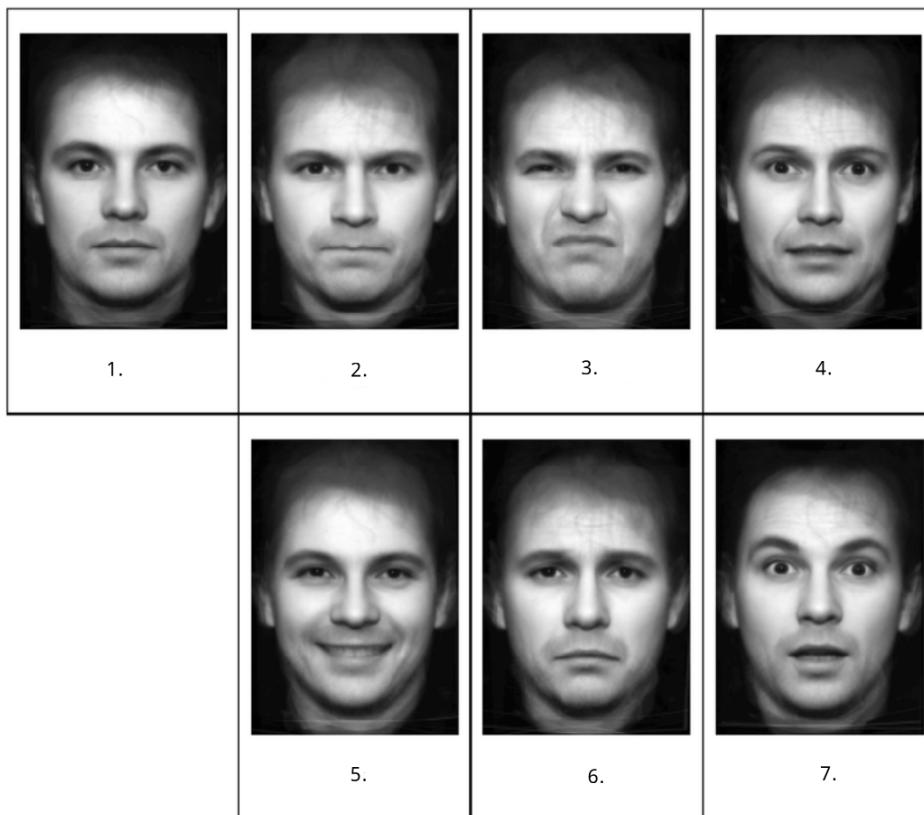
Interakcia človeka s robotickým systémom si vyžaduje nielen technickú presnosť a spoľahlivosť, ale čoraz častejšie aj schopnosť robota porozumieť svojmu ľudskému partnerovi na hlbšej, emocionálnej úrovni. V mnohých oblastiach nasadenia – od priemyslu cez zdravotníctvo až po domáce prostredie – sa ukazuje ako výhodné, ak robot dokáže prispôsobiť svoje správanie aktuálnemu emočnému stavu operátora. Takáto schopnosť môže zvýšiť efektivitu spolupráce, znížiť počet chýb a prispieť k celkovo prirodzenejšej a intuitívnejšej interakcii.

Táto diplomová práca sa zameriava na vytvorenie systému, ktorý bude schopný identifikovať emocionálne rozpoloženie človeka prostredníctvom analýzy výrazu tváre. Zámerom je, aby výsledný modul poskytoval robotickému systému relevantné informácie o emóciách používateľa v reálnom čase. Téma prepája oblasti počítačového videnia, umelej inteligencie a robotiky a reflekтуje narastajúci význam emocionálnej inteligencie v moderných technológiách.

1 Úvod

S rozvojom umelej inteligencie a strojového učenia sa otvárajú nové možnosti pre interakciu medzi človekom a strojom. Jednou z najdôležitejších oblastí výskumu je rozpoznávanie emócií na základe výrazu tváre, ktoré umožňuje strojom porozumieť emocionálnemu stavu používateľa. V kontexte robotických systémov je dôležité, aby roboty boli schopné rozoznať emócie človeka, čo môže zlepšiť komunikáciu, kooperáciu a bezpečnosť pri spoločnej práci [1].

Psychológ Paul Ekman pomenoval šest základných emócií - šťastie, smútok, hnev, strach, prekvapenie a znechutenie - ktoré sú často základom pre zavedené kategórie emócií pri rozpoznávaní tváre. Výber týchto emócií bol založený na ich univerzálnom rozpoznávaní a pozorovaní napriek kultúrami, čo ich predurčuje na použitie v systémoch rozpoznávania tváre.



Obr. 1: Ekmanove základné emócie. 1. neutrálna, 2. hnev, 3. znechutenie, 4. strach, 5. šťastie, 6. smútenie, 7. prekvapenie [2].

Podľa Ekmanovho výskumu sa tieto pocity odrážajú v konkrétnych výrazoch tváre, ktoré dokážu automaticky rozpoznať ľudia zo všetkých kultúrnych prostredí. Jeho práca vytvorila fundamentálny základ pre strojové učenie a psychológiu, najmä pri

vytváraní systémov, ktoré dokážu dešifrovať výrazy tváre na určenie emocionálneho stavu jednotlivca.

V záujme konzistentnosti a presnosti v aplikáciách, ako je zdravotníctvo, robotika a služby zákazníkom, je možné do systémov rozpoznávania tváre zahrnúť konzistentnú metódu analýzy emócií. Pochopenie úrovne spokojnosti alebo podráždenia používateľa môže napríklad pomôcť upraviť reakcie systému a zlepšiť výsledky interakcií [3].

Emócie zohrávajú dôležitú úlohu v procese rozhodovania, riadenia a interakcie. Schopnosť robotického systému porozumieť emocionálnemu stavu používateľa umožňuje jeho prispôsobenie konkrétnym podmienkam a potrebám operátora. Napríklad v prie- mysle môžu robotické systémy identifikovať stres alebo únavu operátora, čím prispievajú k zvýšeniu bezpečnosti a efektivity. Okrem toho, v oblasti zdravotnej starostlivosti môže rozpoznávanie emócií pomôcť monitorovať psychický stav pacientov a prispiet k ich lepšej starostlivosti [4].

Rozpoznávanie emócií je možné dosiahnuť rôznymi metódami, ktoré zahŕňajú spracovanie obrazu, analýzu textu, reč a gestá. Výraz tváre je však najvýznamnejším a najpresnejším indikátorom emócií, pretože vyjadruje okamžitý emocionálny stav človeka. Emócie, ako sú šťastie, smútok, hnev alebo prekvapenie, sú viditeľné prostredníctvom zmien vo svaloch tváre, ktoré sú merateľné a analyzovateľné pomocou technológií strojového učenia, najmä pomocou hlbokých neurónových sietí (Convolutional neural network, v slovenčine *konvolučná neurónová sieť* (CNN)) [1].

Súčasné metódy na rozpoznávanie emócií zahŕňajú viacero prístupov. Tradičné prístupy, ako napríklad metódy založené na geometrických črtách a textúrach, boli doplnené modernými metódami založenými na hlbokom učení, ktoré dosahujú vysokú presnosť. Neurónové siete sú schopné automaticky extrahovať črty tváre bez potreby manuálneho zásahu, čo výrazne zvyšuje efektivitu systému. Tieto pokročilé modely dosahujú vysokú mieru úspešnosti v rôznych aplikáciách, ako sú zdravotná starostlivosť alebo priemyselná automatizácia [4] [5].

1.1 Motivácia

V súčasnej dobe, keď technológie prenikajú do všetkých aspektov ľudského života, je nevyhnutné, aby robotické systémy disponovali nielen kognitívnymi schopnostami, ale aj emocionálnou inteligenciou. Táto schopnosť umožňuje robotom identifikovať, hodnotiť a reagovať na emócie ľudí, čím sa zvyšuje efektivita a prirodzenosť interakcie medzi človekom a strojom. Emocionálna inteligencia zahŕňa schopnosť rozpoznávať vlastné emócie, emócie iných, a adekvátnie na ne reagovať.

V oblasti interakcie človeka s robotom (Human-Robot Interaction, HRI) je rozpoznávanie emócií klúčové pre vytvorenie intuitívnej a efektívnej spolupráce. Roboty schopné interpretovať emocionálny stav operátora môžu prispôsobiť svoje správanie aktuálnej situácie, čo je obzvlášť dôležité v oblastiach, kde je potrebná vysoká miera spolupráce a dôvery, ako napríklad v zdravotníctve, vzdelávaní či v priemyselnej výrobe. Napríklad v zdravotníctve môžu roboty asistovať pacientom s emocionálnou podporou, monitorovať ich psychický stav a poskytovať adekvátne reakcie na základe rozpoznaných emócií [6].

Aktuálne trendy v oblasti robotiky smerujú k vývoju systémov, ktoré dokážu nielen vykonávať predprogramované úlohy, ale aj adaptovať sa na dynamické prostredie a emocionálne potreby používateľov. Výskum v oblasti afektívnej robotiky sa zameriava na integráciu emocionálnych modelov do robotických systémov, čo umožňuje lepšie porozumenie a predikciu ľudského správania. Napriek pokroku v tejto oblasti existujú výzvy spojené s presnosťou rozpoznávania emócií, interpretáciou komplexných emocionálnych stavov a zabezpečením etického využitia týchto technológií [6].

Implementácia systému na identifikáciu emócií operátora na základe výrazu tváre predstavuje významný krok k zlepšeniu interakcie medzi človekom a robotom. Takýto systém môže prispieť k vyšej efektivite, bezpečnosti a spokojnosti používateľov pri práci s robotickými systémami. Napríklad v priemyselných aplikáciách môže robot upraviť svoj pracovný rytmus alebo poskytnúť upozornenie v prípade, že deteguje stres alebo únavu operátora, čím sa predchádza možným chybám alebo nehodám.

Celkovo je motivácia pre vývoj takýchto systémov založená na snahe o vytvorenie robotických asistentov, ktorí sú schopní nielen technicky podporovať človeka, ale aj empaticky reagovať na jeho emocionálne potreby, čím sa zvyšuje kvalita a efektivita ich vzájomnej spolupráce. Motiváciou pre rozpoznávanie emócií tváre je jeho potenciál zlepšiť interakciu medzi človekom a počítačom, zlepšiť monitorovanie duševného zdravia a vytvoriť adaptívne systémy pre rôzne oblasti, ako je vzdelávanie, marketing a robotika [6].

1.2 Ciele práce

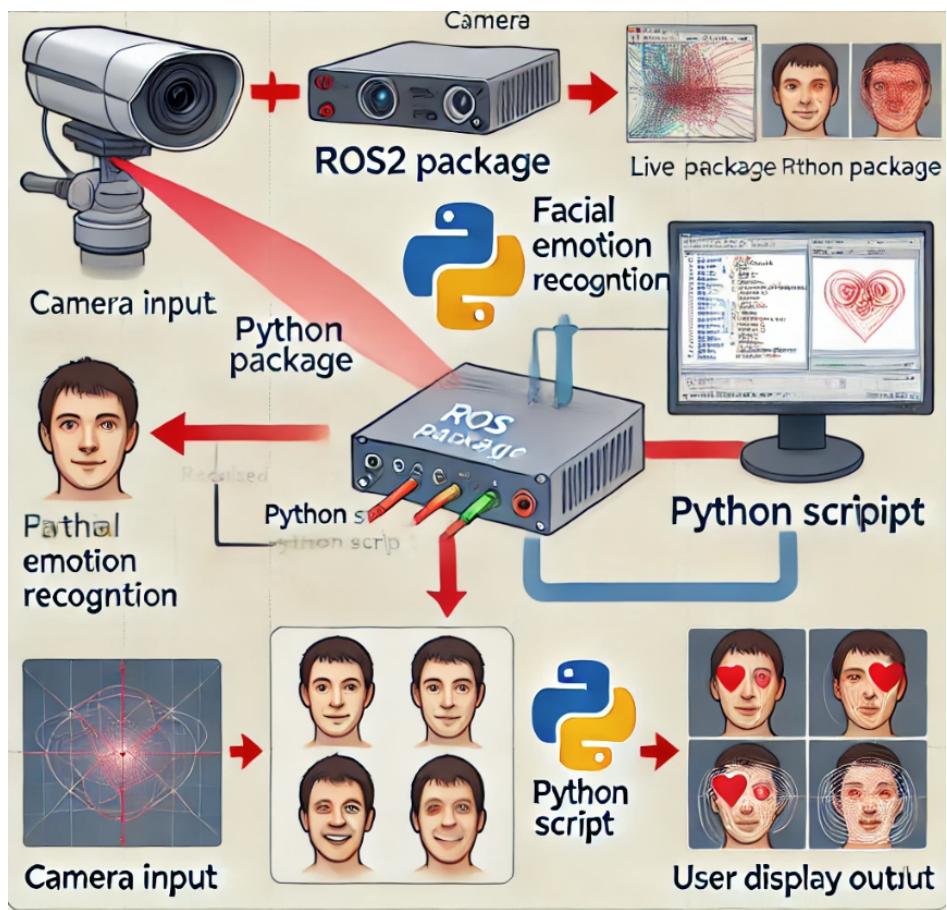
Cieľom tejto práce je navrhnuť, implementovať a otestovať systém, ktorý bude schopný identifikovať emocionálny stav človeka na základe výrazu jeho tváre v reálnom čase. Takýto systém má potenciál výrazne zlepšiť interakciu človeka s robotickým systémom, najmä v prostredí, kde je dôležitá adaptácia robota na aktuálny psychický stav operátora.

Hlavný dôraz je kladený na vytvorenie robustného a presného modulu na rozpoznávanie emócií, ktorý bude možné integrovať do existujúcich robotických platform v prostredí ROS2 (Robot Operating System 2). V práci sa uvažuje s využitím RGB kamery.

Práca sa zameriava na splnenie nasledujúcich čiastkových cieľov:

- Analýza existujúcich metód rozpoznávania emócií na základe výrazu tváre – preskúmanie prístupov založených na tradičnom strojovom učení (SVM, HOG + LBP), ako aj moderných hlbokých neurónových sietí (CNN, ResNet, SE-ResNet, atď.)
- Štúdium biometrických modelov tváre a techník detekcie tváre – skúmanie metód ako Haar Cascade, MTCNN, Dlib a OpenCV moduly na detekciu a orezanie tváre.
- Návrh architektúry systému na rozpoznávanie emócií – vybudovanie modelu (napr. ResEmoteNet) využívajúceho konvolučné siete a reziduálne bloky, schopného klasifikovať emócie ako radosť, smútok, hnev, prekvapenie, odpor a strach.
- Tréning a testovanie systému na open-source databázach – použitie datasetov ako FER2013, RAF-DB, AffectNet a KDEF na overenie presnosti a generalizácie modelu.
- Vytvorenie ROS2 balíka – implementácia systému do samostatného ROS2 balíka, ktorý poskytne výstup emocionálneho stavu ako ROS2 téma (napr. emotion_topic).
- Validácia a experimentálne vyhodnotenie systému – testovanie modelu na reálnych aj simulovaných dátach, s dôrazom na presnosť, rýchlosť spracovania a robustnosť voči zmenám osvetlenia či polohy tváre.

Cieľom je vytvoriť systém, ktorý bude nielen presný a spoľahlivý, ale aj dostatočne efektívny na to, aby mohol byť nasadený v reálnom čase na vstavaných výpočtových zariadeniach ako NVIDIA Jetson alebo Raspberry Pi 4 a COCOHRIP. Systém by mal byť zároveň jednoducho škálovateľný a rozšíriteľný o ďalšie vstupy (napr. hlas, srdcovú frekvenciu alebo EDA senzory), čo otvorí cestu k multimodálnemu rozpoznávaniu emócií. Cieľom práce je vytvoriť systém, ktorý bude schopný rozpoznať emócie v reálnom čase.



Obr. 2: Schéma systému na rozpoznávanie emócií operátora pomocou RGB kamery.

2 Teoretické základy

2.1 Emócie a ich prejav

Emócie predstavujú základný prvok ľudskej psychiky a zohrávajú kľúčovú úlohu pri vnímaní, rozhodovaní a správaní človeka. Ide o komplexné psychologické stavy, ktoré sú výsledkom interakcie medzi subjektívnymi prežitkami, fyziologickými reakciami a behaviorálnymi prejavmi. Emócie sú neoddeliteľnou súčasťou medziľudskej komunikácie a výrazne ovplyvňujú spôsob, akým človek interpretuje a reaguje na svoje okolie [6].

V oblasti rozpoznávania emócií je dôležité chápať, že emocionálne stavy sa môžu prejavovať prostredníctvom viacerých modalít – výrazu tváre, reči, gest, telesného pohybu a fyziologických parametrov. V tejto práci sa zameriavame predovšetkým na výraz tváre, keďže ide o najvýraznejší a najintuitívnejší indikátor emocionálneho stavu, ktorý je zároveň vhodný na analýzu pomocou techník počítačového videnia.

Podľa výskumu psychológa Paula Ekmana existuje šesť základných emócií, ktoré sú univerzálne rozpoznateľné na základe výrazu tváre naprieč kultúrami: radosť, smútok, hnev, strach, prekvapenie a odpor. Tieto emócie majú charakteristické črty, ktoré sú podmienené aktivitou konkrétnych svalových skupín v tvári. Napríklad radosť sa často prejavuje zdvihnutím kútikov úst a vytvorením vrások okolo očí, zatiaľ čo hnev býva charakterizovaný znížením obočia a stiahnutými perami [4].

Význam výrazu tváre ako neverbálneho komunikačného kanála podčiarkuje aj výskum, ktorý ukazuje, že až 55 % emocionálnych informácií v interpersonálnej komunikácii je sprostredkovaných cez tvár. Tento údaj zdôrazňuje dôležitosť správnej analýzy mimiky pri snahe strojovo identifikovať emócie.

Z praktického hľadiska má analýza výrazu tváre široké uplatnenie. V oblasti združovanej starostlivosti môže pomáhať monitorovať psychický stav pacientov, v automotive sektore identifikovať únavu alebo stres vodiča, a v robotike zvyšovať adaptabilitu robotických systémov pri práci s ľuďmi .

Z výskumného pohľadu je preto nevyhnutné dôkladne porozumieť tomu, ako sa emócie prejavujú vo výraze tváre, a akými algoritmickými prístupmi je možné tieto prejavy detegovať a interpretovať. To tvorí východisko pre praktickú časť práce, kde sa tieto teoretické poznatky pretavia do konkrétneho technického riešenia.

2.1.1 Kultúrne rozdiely v prejave emócií

Aj napriek existencii univerzálnych emócií existujú značné kultúrne rozdiely v tom, ako sú emócie prejavované a interpretované. Kultúrne normy a spoločenské očakávania môžu výrazne ovplyvniť intenzitu, frekvenciu a spôsob vyjadrenia emócií.

V tzv. individualistických kultúrach (napr. západná Európa alebo USA) je emocionálny prejav väčšinou priamy a otvorený. Naopak, v kolektivistických kultúrach (napr. východná Ázia) býva prejav emócií častejšie potláčaný alebo upravený v záujme zachovania harmónie v skupine.

Tieto kultúrne odlišnosti predstavujú výzvu pre univerzálne systémy rozpoznávania emócií, pretože rovnaký výraz tváre môže byť interpretovaný odlišne v závislosti od kultúrneho kontextu. Z tohto dôvodu je v niektorých prípadoch výhodné využiť aj regionálne adaptované modely, alebo multimodálne systémy, ktoré pracujú s doplňujúcimi vstupmi (reč, gestá, fyziologické signály).

2.1.2 Výrazy tváre ako indikátory emócií

Výraz tváre je jedným z najdôležitejších vizuálnych prejavov emocionálneho stavu človeka. Ide o dynamický proces, pri ktorom sa aktivujú rôzne skupiny mimických svalov a vytvárajú charakteristické konfigurácie typické pre jednotlivé emócie. Napríklad zdvihnutie kútikov úst je typické pre radosť, stiahnutie obočia smerom dovnútra pre hnev a zdvihnutie vnútorných častí obočia často signalizuje smútok.

Tieto konfigurácie boli formalizované v rámci systému FACS (Facial Action Coding System), ktorý vyvinul Ekman spolu s Friesenom. FACS poskytuje štandardizovaný spôsob, ako kvantifikovať a analyzovať pohyby svalov tváre, čím sa stal základom pre mnohé moderné algoritmy rozpoznávania emócií [7].

Vzhľadom na to, že výraz tváre je jedným z najvýraznejších a najinformatívnejších neverbálnych prejavov človeka, biometrické systémy ho často využívajú ako klúčový vizuálny vstup. Jeho vysoká výpovedná hodnota z pohľadu emocionálneho rozpoloženia, ako aj relatívna jednoduchosť snímania, robia z tváre ideálny objekt pre pasívne rozpoznávanie v reálnom čase. Táto vizuálna modalita je preto prirodzene preferovaná v aplikáciách počítačového videnia a umelej inteligencie, kde hrá zásadnú rolu pri autentifikácii osôb aj pri odhadovaní ich psychického stavu.

2.2 Analýza obrazu

Analýza obrazu je klúčovým prvkom systému rozpoznávania emócií, pretože umožňuje spracovať vizuálny vstup a získať z neho relevantné črty tváre, ktoré sú následne použité na klasifikáciu emocionálneho stavu. Tento proces sa zvyčajne skladá z troch základných krokov:

- **Detekcia tváre** – určenie polohy tváre v obraze,
- **Extrakcia príznakov** – získanie vizuálnych črt z detegovanej tváre,

- **Klasifikácia** – priradenie emócie na základe získaných črt.

Tieto kroky je možné realizovať pomocou klasických metód počítačového videnia, ako aj s využitím moderných hlbokých neurónových sietí, ktoré často spájajú všetky tri fázy do jedného end-to-end modelu.

2.2.1 Detekcia tváre

Detekcia tváre je prvým krokom pri analýze obrazu. Ide o proces lokalizácie oblasti tváre v snímke, ktorý slúži ako základ pre ďalšie spracovanie. Existujú dve základné kategórie prístupov: klasické (ručne definované príznaky) a moderné (hlboké učenie).

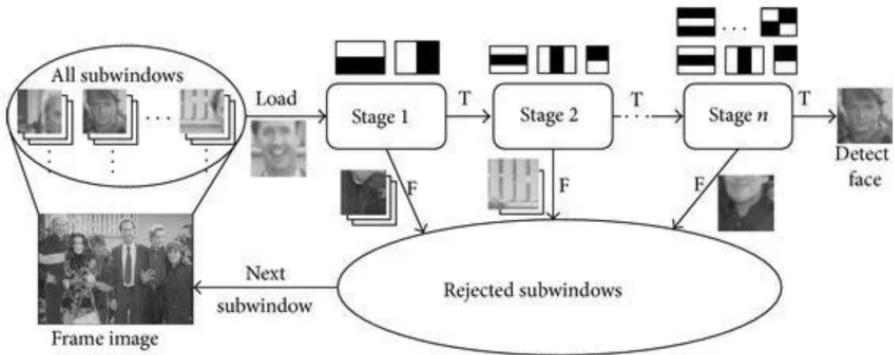
Viola-Jones (Haar Cascade) Algoritmus Viola-Jones využíva tzv. Haar-like príznaky a Adaboost klasifikátor trénovaný na veľkom množstve tvári. Výhodou je nízka výpočtová náročnosť, vďaka čomu je vhodný aj pre zariadenia s obmedzeným výkonom. Slabinou je citlivosť na uhol natočenia tváre a osvetlenie.

SSD Face Detection Metóda Single Shot MultiBox Detector (SSD) patrí medzi hlboké konvolučné modely schopné detektovať tváre v reálnom čase. Vstupný obraz sa normalizuje a spracúva sietou, ktorá výstupom poskytuje ohraničujúce boxy a skóre istoty (confidence score). Výhodou je schopnosť robustnej detekcie aj pri zakrytí časti tváre alebo v zhoršených svetelných podmienkach.

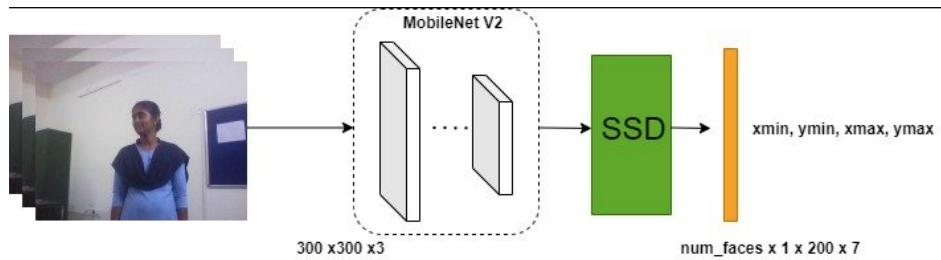
Iné pokročilé metódy Ďalšie populárne detektory zahŕňajú:

- **MTCNN** (Multi-task CNN): detekcia spolu s lokalizáciou klúčových bodov tváre,
- **YOLO-Face**: adaptácia YOLO modelu pre vysokorýchlosnú detekciu tvári,
- **RetinaFace**: detektor schopný presne odhadnúť aj pózu a tvar tváre.

Moderné metódy sa bežne trénujú na datasetoch ako WIDER-Face alebo FDDB a dosahujú vysokú presnosť i rýchlosť.



Obr. 3: Detekcia tváre pomocou Haar Cascade [8].



Obr. 4: Detekcia tváre pomocou SSD modelu [9].

2.2.2 Extrakcia príznakov

Po úspešnej detekcii tváre nasleduje fáza extrakcie príznakov (feature extraction), kde sa analyzujú črty ako oči, ústa, obočie, nos a ich relatívne pozicie. Existujú dva hlavné prístupy:

- **Geometrické príznaky:** meranie vzdialenosí a uhlov medzi bodmi (napr. vzdialosť medzi očami),
- **Textúrne príznaky:** využívajú sa filtre ako Gabor, LBP (Local Binary Patterns) alebo HOG (Histogram of Oriented Gradients).

Moderné prístupy využívajú CNN, ktoré automaticky extrahujú hierarchické príznaky z obrazových dát bez potreby manuálneho návrhu črt. Tento spôsob je robustnejší voči zmenám osvetlenia, výrazu a šumu.

2.2.3 Klasifikácia

Klasifikácia je záverečným krokom v analýze obrazu, kde sa príznaky spracované z predchádzajúcej fázy priradujú k určitej kategórii emócií. V tradičných systémoch sa používali metódy ako:

- Support Vector Machines (SVM),
- Random Forest,
- K-Nearest Neighbors (k-NN).

V súčasnosti sa najčastejšie používajú hlboké neurónové siete, predovšetkým CNN, prípadne ich kombinácie s Recurrent neural network, v slovenčine *rekurentná neurónová sieť* (RNN) alebo LSTM pre spracovanie časových sekvencií vo videách.

2.3 Biometria

Biometria je vedný odbor zaobrajúci sa rozpoznávaním a identifikáciou osôb na základe ich jedinečných fyziologických alebo behaviorálnych charakteristík. V kontexte tejto práce sa biometria sústreduje predovšetkým na biometriu tváre, ktorá využíva špecifické črty ľudskej tváre na autentifikáciu, verifikáciu alebo identifikáciu jednotlivcov.

Rozpoznávanie tváre patrí medzi najpoužívanejšie a najprirodzenejšie biometrické techniky. Na rozdiel od iných biometrických metód (napr. odtlačky prstov alebo dúhovka), tvár je voľne dostupná a možno ju snímať neinvazívne aj bez vedomia pozorovaného subjektu, čo otvára možnosti pre pasívne monitorovanie, ale zároveň vyžaduje dôsledné riešenie otázok ochrany súkromia[10] [4].

2.3.1 Princípy biometrických systémov

Každý biometrický systém pozostáva z nasledujúcich hlavných komponentov:

- **Zachytávanie zariadenie** – typicky kamera (RGB alebo RGB-D), ktorá sníma obraz tváre.
- **Predspracovanie** – normalizácia osvetlenia, vyrovnanie orientácie a orezanie oblasti tváre.
- **Extrakcia príznakov** – získanie reprezentatívnych črt pomocou geometrických, textúrnych alebo hlbokých metód.
- **Porovnanie** – porovnanie aktuálne extrahovaných črt s referenčnými dátami (napr. v databáze).
- **Rozhodovanie** – určenie, či záznam zodpovedá známej osobe (verifikácia) alebo ktorá osoba to je (identifikácia).

Úspešnosť biometrického systému závisí od kvality vstupných dát, výberu algoritmu, robustnosti extrakcie príznakov a schopnosti pracovať s variabilitami, ako sú zmeny výrazu tváre, osvetlenia, uhla alebo čiastočného zakrytie.

2.3.2 Identifikácia vs. verifikácia

V biometrických systémoch rozlišujeme dva základné režimy spracovania: verifikáciu a identifikáciu. Hoci sa tieto pojmy častejšie spájajú s rozpoznávaním identity osoby, ich princípy možno analogicky aplikovať aj v kontexte rozpoznávania emócií.

- **Verifikácia** – v kontexte emocionálnej biometrie znamená overenie, či sa aktuálny emocionálny stav zhoduje s očakávaným alebo referenčným stavom. Napríklad, ak systém očakáva, že operátor je pokojný pred začiatkom operácie, môže porovnať aktuálny emocionálny profil s „normálnym“ vzorom, aby overil, či je operátor pripravený vykonávať úlohu.
- **Identifikácia** – v tomto kontexte predstavuje určenie, aký emocionálny stav operátor aktuálne prežíva – napríklad či ide o radosť, smútok, stres alebo hnev. Tento prístup je typický pre afektívne systémy, ktoré potrebujú rozpoznať emóciu bez vopred definovaného očakávania.

V navrhovanom systéme sa primárne pracuje s identifikáciou emocionálnych stavov v reálnom čase. V budúcnosti by však mohla byť kombinácia oboch režimov užitočná napríklad v prípadoch, kde robot overuje, či je používateľ v bezpečnom a vhodnom emočnom rozpoložení pred vykonaním citlivej úlohy.

2.3.3 Výhody a výzvy biometrie tváre

Rozpoznávanie tváre má oproti iným biometrickým metódam viacero výhod:

- neinvazívnosť a bezkontaktnosť,
- vhodnosť pre sledovanie v reálnom čase,
- vysoká akceptovateľnosť u používateľov,
- možnosť kombinácie s inými modalitami (hlas, gesta, emócie).

Medzi hlavné výzvy patrí:

- variabilita výrazu tváre (napr. úsmev vs. hnev),
- zmeny spôsobené vekom, svetelnými podmienkami alebo pohybom,
- zakrytie tváre (napr. rúška, okuliare),
- etické a legislatívne otázky súvisiace s ochranou súkromia a spracovaním biometrických údajov.

Tieto faktory musia byť zohľadnené najmä v aplikáciách v reálnom svete, kde je požadovaná vysoká robustnosť a spoľahlivosť systému.

3 Existujúce metody analýzy emócií

V oblasti rozpoznávania emócií na základe výrazu tváre existuje mnoho prístupov, ktoré môžeme rozdeliť na manuálne a automatizované metódy. Kým tradičné manuálne prístupy spočívajú v ručnom označovaní výrazov tváre, moderné metódy využívajú automatické algoritmy, často založené na neurónových sietach (NN).

3.1 Ručné značenie

Ručne značenie (manuálna anotácia) spočíva v označovaní kľúčových bodov na tvári a následnom priradení výrazov tváre k určitým emočným kategóriám. Tento proces je časovo náročný a vyžaduje expertov na interpretáciu dát. Avšak, ručné značenie je stále dôležité pre tvorbu datasetov, ktoré sú nevyhnutné na trénovanie automatických systémov. Dôležité datasetové projekty, ako sú Cohn-Kanade alebo AffectNet, sa opierajú o ručné značenie výrazov tváre. Manuálna anotácia má významnú úlohu v počiatočných fázach výskumu, ale pre aplikácie, ktoré vyžadujú veľké množstvo dát, je neefektívna [6].

Pre kvalitný výstup modelu je nevyhnutné disponovať **presnými a konzistentnými anotáciami**. Nekonzistentné alebo chybné značkovanie môže výrazne ovplyvniť výslednú presnosť modelu, preto je vhodné, aby anotáciu vykonávali vyškolení ľudia a prípadne sa zabezpečila viacnásobná anotácia (napr. metóda majority voting).

3.2 Automatická analýza emócií

Automatická analýza emócií predstavuje pokročilý spôsob interpretácie emocionálneho stavu človeka bez potreby manuálneho zásahu. Využíva najnovšie metódy počítačového videnia a strojového učenia, ktoré umožňujú strojom rozpoznať emócie na základe výrazu tváre v reálnom čase. Cieľom takýchto systémov je identifikovať jemné zmeny v mimike a priradiť ich k zodpovedajúcej kategórii emócie.

Moderné prístupy sa vo veľkej miere spoliehajú na architektúry hlbokého učenia, predovšetkým na CNN, ktoré automaticky extrahujú relevantné črty z obrazu tváre. Kombináciou týchto sietí s rekurentnými architektúrami, ako sú RNN a Long short-term memory, v slovenčine *dlhodobá krátkodobá pamäť* (LSTM), je možné efektívne analyzovať aj dynamiku výrazu tváre v čase, čím sa výrazne zvyšuje presnosť rozpoznávania pre videozáznamy a reálne situácie [6] [11].

3.2.1 Konvolučné neurónové siete

Konvolučné neurónové siete (CNN) sú inšpirované biologickými procesmi vo vizuálnom kortexe a patria medzi najefektívnejšie metódy spracovania obrazových dát. V kontexte rozpoznávania emócií sú CNN schopné automaticky extrahovať príznaky výrazu tváre bez potreby ručnej definície, čím zjednodušujú a zrýchľujú proces spracovania. Ich viacvrstvová architektúra umožňuje postupnú extrakciu od základných črt (napr. hrany a krivky) až po komplexnejšie tvárové štruktúry ako sú oči, obočie, ústa či lícne svaly.

Zásadnou výhodou CNN je ich robustnosť voči variabilite v osvetlení, uhle pohľadu a individuálnych rozdieloch medzi ľudmi. Tieto vlastnosti z nich robia ideálnu voľbu pre reálne nasadenie do systémov rozpoznávania emócií [12].

3.2.2 Typy vhodných neurónových sietí

Pre aplikácie rozpoznávania emócií sa najčastejšie využívajú nasledovné typy hlbokých neurónových sietí:

- **CNN:** Používané na extrakciu priestorových črt tváre z jednotlivých obrázkov. Sú schopné zachytiť štruktúry tváre aj pri rôznych výrazoch a uhle natočenia.
- **RNN a LSTM:** Rekurentné siete sú vhodné pre spracovanie časových sekvenčí, ako sú videozáznamy mimiky. Ich schopnosť uchovávať predchádzajúce stavy umožňuje sledovať zmeny vo výraze v čase, čo je klúčové pri rozpoznávaní prechodových emócií alebo mikroexpresií [13].
- **Deep convolutional neural network, v slovenčine *hlboká konvolučná neurónová sieť* (DCNN):** Hlboké konvolučné siete predstavujú pokročilejší variant CNN, ktorý zahŕňa väčší počet vrstiev a často aj reziduálne alebo SE bloky. Používajú sa v systémoch s dôrazom na vysokú presnosť a zložitejšiu klasifikáciu emócií v náročných podmienkach.

3.2.3 Príklady použitia počítačového videnia

Automatické rozpoznávanie emócií je úzko prepojené s oblasťou počítačového videnia. Táto disciplína sa zaobrá extrakciou a analýzou vizuálnych informácií z obrazových vstupov. CNN modely sa často kombinujú s tradičnými technikami extrakcie črt, ako sú **HOG (Histogram of Oriented Gradients)** alebo **SIFT (Scale-Invariant Feature Transform)**, ktoré pomáhajú zlepšiť robustnosť systému, najmä v prípade rušivých podmienok.

Tieto systémy sú navrhnuté tak, aby dokázali identifikovať a klasifikovať emocionálne výrazy aj v podmienkach ako sú:

- nehomogénne alebo slabé osvetlenie,
- čiastočné zakrytie tváre (napr. rúškom, rukou, okuliarmi),
- rôzne etnické alebo vekové skupiny,
- nečakané výrazy (kombinácie viacerých emócií).

Dôkazom úspešnosti týchto prístupov je ich nasadenie v reálnych aplikáciách, napríklad v zákazníckych centrách, automobilovom priemysle (detekcia únavy vodiča), v zdravotníctve (monitorovanie pacientov) či v robotike (adaptívne roboty s afektívnou spätnou väzbou) [10].

4 Návrh riešenia

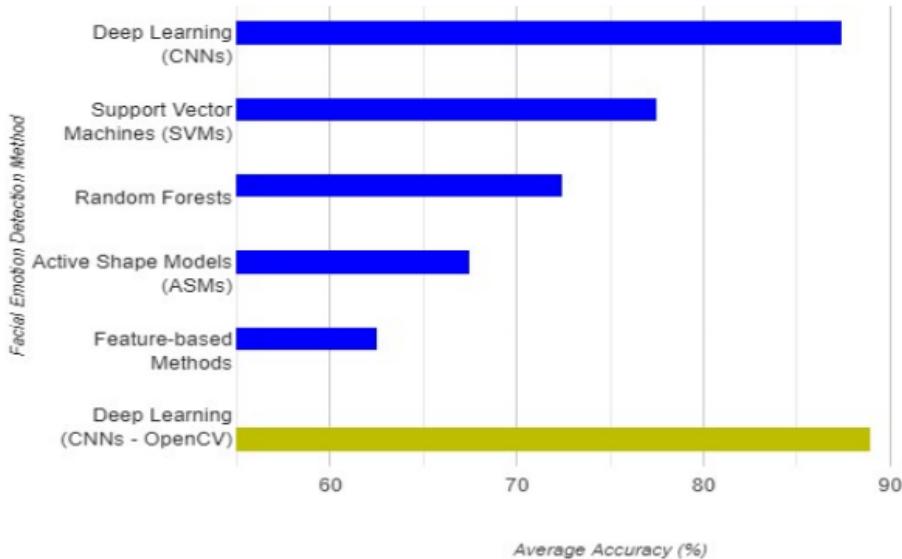
4.1 Porovnanie vybraných metód

V tejto práci boli analyzované a porovnané viaceré prístupy k rozpoznávaniu emócií z výrazu tváre, pričom pozornosť bola venovaná najmä metódam využívajúcim techniky hlbokého učenia. Tradičné prístupy, ako sú kombinácie geometrických a textúrnych príznakov (napr. HOG + LBP) so strojovým učením (napr. SVM), vykazujú určitú úroveň úspešnosti najmä pri dobre osvetlených a centrálnie zarovnaných snímkach, avšak ich robustnosť v reálnych podmienkach je obmedzená.

Naopak, architektúry založené na konvolučných neurónových sietach (CNN) dokážu automaticky extrahovať relevantné črty tváre a lepšie sa vyrovnať s rôznorodostou v osvetlení, pôzach a výrazoch. Porovnané boli viaceré známe CNN modely, vrátane:

- VGGFace – hlboká architektúra s jednoduchou štruktúrou, ktorá však má veľký počet parametrov a vyššie výpočtové nároky.
- ResNet – siet s reziduálnymi blokmi, ktorá vďaka svojmu návrhu lepšie rieši problém miznúcich gradientov pri hlbších modeloch.
- SE-ResNet – rozšírenie ResNetu o SE (Squeeze-and-Excitation) bloky, ktoré umožňujú lepšie zvýrazniť významné kanály.
- ResEmoteNet – vlastná modifikovaná architektúra použitá v tejto práci, ktorá kombinuje výhody reziduálnych a SE blokov, pričom je optimalizovaná na klasifikáciu emócií v reálnom čase.

V navrhovanom systéme sa ako hlavná metóda detektie tváre z videa využíva model SSD (Single Shot MultiBox Detector), ktorý je schopný robustne lokalizovať tváre aj pri rôznych uhloch pohľadu, čiastočnom zakrytí a meniacich sa svetelných podmienkach. SSD bol zvolený pre svoju rýchlosť a presnosť v reálnom čase, čo ho predurčuje na použitie v interaktívnych robotických aplikáciách.



Obr. 5: porovnanie rôznych metód na rozpoznávanie emócií [14].

4.2 Architektúra systému ResEmoteNet

ResEmoteNet predstavuje pokročilú architektúru hlbokého učenia navrhnutú špeciálne na rozpoznávanie emócií na základe výrazu tváre. Využíva kombináciu konvolučných neurónových sietí (CNN), reziduálnych blokov a Squeeze-Excitation (SE) blokov, čím dosahuje vysokú presnosť pri klasifikácii emócií a zároveň minimalizuje straty modelu. Táto architektúra je optimalizovaná na spracovanie vizuálnych dát z rôznych datasetov a poskytuje robustné riešenie pre reálne aplikácie.

4.2.1 Hlavné komponenty architektúry

- **Konvolučné vrstvy (CNN):** Slúžia na hierarchickú extrakciu črt tváre. Obsahujú tri konvolučné vrstvy, každá s následnou normalizáciou dávky (Batch Normalization) na stabilizáciu učenia a zvýšenie efektivity tréningu. Max-pooling vrstvy redukujú priestorové rozmery, čím znížujú výpočtovú náročnosť a zvyšujú robustnosť voči transláciám.
- **Reziduálne bloky:** Tri reziduálne bloky umožňujú modelu učiť sa komplexnejšie reprezentácie dát prostredníctvom hlbších vrstiev. Reziduálne spojenia zmierňujú problém gradientového zmiznutia, čo vedie k lepšiemu výkonu modelu pri spracovaní veľkých datasetov.
- **Squeeze-Excitation (SE) bloky:** SE bloky selektívne zdôrazňujú dôležité črty tváre a potláčajú menej relevantné informácie. Tento mechanizmus zlepšuje reprezentáciu črt a prispieva k vyššej presnosti klasifikácie.

4.2.2 Prínosy architektúry ResEmoteNet

- **Redukcia strát:** Integrácia SE blokov pomáha minimalizovať straty modelu, čím sa zvyšuje celkový výkon.
- **Vysoká presnosť:** Model dosiahol presnosť 79,79 % na datasete FER2013, 94,76 % na RAF-DB, 72,93 % na AffectNet-7 a 75,67 % na ExpW.
- **Robustnosť:** Vynikajúca odolnosť voči variáciám osvetlenia, pózy a zakrytie tváre.
- **Efektívnosť:** Optimalizované parametre (napr. dávková velkosť 16 a 80 epoch) zabezpečujú rýchlu konvergenciu počas tréningu.

4.2.3 Experimentálne výsledky

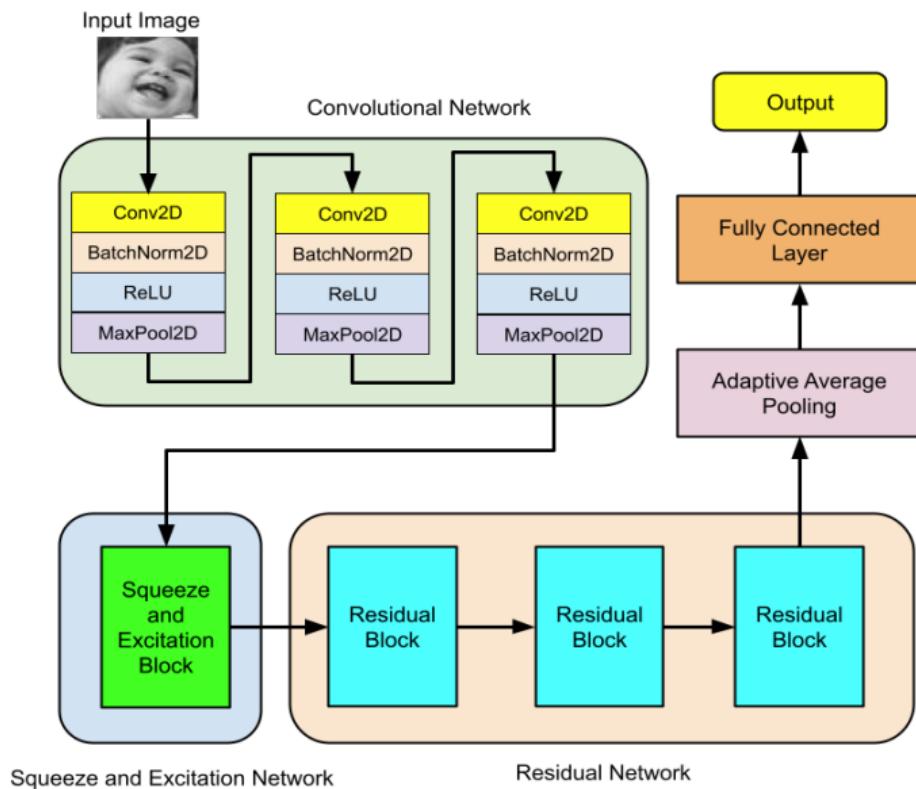
ResEmoteNet bol testovaný na štyroch otvorených datasetoch:

- **FER2013:** Výzvou sú nepresné anotácie a nerovnomerné rozloženie dát, no model dosiahol presnosť 79,79 %, čo je zlepšenie o 2,97 % oproti predchádzajúcim metódam.
- **RAF-DB:** Dataset obsahuje reálne výzvy ako póza či osvetlenie; model dosiahol presnosť 94,76 %, čo je o 2,19 % viac oproti konkurencii.
- **AffectNet-7:** Rozsiahly dataset s rôznorodými anotáciami; presnosť modelu bola 72,93 %, čo predstavuje zlepšenie o 3,53 %.
- **ExpW:** Dataset s nekontrolovanými výrazmi tvári v reálnom svete; model dosiahol presnosť 75,67 %, čo je o 2,19 % viac oproti predchádzajúcim metódam.

4.2.4 Schéma architektúry systému

Architektúra pozostáva z kombinácie konvolučných vrstiev, SE blokov a reziduálnych blokov. Tieto komponenty sú integrované do jedného robustného systému schopného efektívne spracovať vizuálne dáta v reálnom čase.

ResEmoteNet predstavuje významný pokrok v oblasti rozpoznávania emócií na základe výrazu tváre. Jeho schopnosti ho predurčujú na široké využitie v oblastiach ako sociálna robotika, zdravotníctvo či interakcia človek-stroj.



Obr. 6: Architektúra systému na rozpoznávanie emócií operátora pomocou RGB kamery [11].

4.3 Výber dát

Hlavným datasetom použitým v tejto práci je **RAF-DB (Real-world Affective Faces Database)**, ktorý bol zvolený pre svoju vysokú kvalitu a realistické podmienky. Dataset obsahuje približne **15 000 obrázkov** tvári s rozlíšením 100×100 pixelov, ktoré sú anotované do **7 základných emócií** (štastie, smútok, hnev, prekvapenie, strach, znechutnenie a neutrálne) a **12 zložených emočných stavov**.

4.3.1 Dôvody výberu RAF-DB

- **Reálne podmienky:** Obrázky zahŕňajú rôzne osvetlenie, pózy tváre, vekové skupiny a etnickú príslušnosť.
- **Prirodzenosť výrazov:** Emócie sú zachytené v reálnych scenároch, čo zvyšuje robustnosť modelu pri nasadení do praxe.
- **Balansované rozloženie tried:** Každá emočná kategória obsahuje približne 1 000–1 500 obrázkov, čo minimalizuje riziko predpojatosti modelu.

4.3.2 Porovnanie s inými datasetmi

Dataset	Počet obrázkov	Rozlíšenie	Výhody	Obmedzenia
RAF-DB	15 000	100×100	Reálne podmienky, zložené emócie	Menšia veľkosť oproti AffectNet
AffectNet	1 000 000+	Rôzne	Veľkosť, anotácia kontinuálnych emócií	Nerovnomerné rozloženie tried
CK+	593 sekvencií	640×490	Vysoká kvalita, dynamika výrazov	Umelé vyvolané emócie
FER2013	35 887	48×48	Štandardizované porovnanie	Nízke rozlíšenie, nepresné anotácie

Tabuľka 1: Porovnanie vybraných datasetov na rozpoznávanie emócií

4.3.3 Prínos pre prácu

Výber RAF-DB je klúčový pre ciele tejto práce z nasledujúcich dôvodov:

- **Real-time aplikácie:** Umožňuje testovanie modelu v podmienkach blízkych reálnemu nasadeniu (variabilita osvetlenia, pózy).

- **Validácia robustnosti:** Prítomnosť čiastočne zakrytých tvári a komplexných výrazov overuje schopnosť systému generalizovať.
- **Kompatibilita s ROS2:** Optimalizovaná veľkosť obrázkov (100×100 px) znižuje výpočtovú náročnosť pre vstavané zariadenia ako NVIDIA Jetson.

4.3.4 Príprava dát

Pre trénovanie modelu boli dáta rozdelené v pomere **80:10:10** (trénovacie:validačné:testovacie). Na zvýšenie variability trénovacích vzoriek bola použitá augmentácia dát:

- Rotácia $\pm 20^\circ$,
- Horizontálne preklopenie,
- Úpravy jasu a kontrastu.

Výber datasetu RAF-DB poskytuje ideálny základ pre vývoj systému na rozpoznávanie emócií operátora v reálnom čase. Jeho vlastnosti umožňujú efektívne testovanie a validáciu navrhnutého modelu v rôznych podmienkach.

4.4 Extrakcia príznakov

Extrakcia príznakov je kritickou fázou v rozpoznávaní emócií, ktorá transformuje surové obrazové dáta na informačne bohaté reprezentácie vhodné pre klasifikáciu. Tento proces zahŕňa kombináciu geometrických, textúrnych a hlbokých prístupov.

4.4.1 Metódy extrakcie príznakov

- **Geometrické príznaky:**
 - Meranie vzdialenosí a uhlov medzi 68 klúčovými bodmi tváre (Dlib)
 - Príklad: Vzdialosť medzi obočím pri hneve ($\uparrow 15\text{-}20\%$ oproti neutrálu)
- **Textúrové príznaky:**
 - LBP (Local Binary Patterns) pre lokálne textúry
 - HOG (Histogram of Oriented Gradients) pre orientáciu hran
 - Príklad: LBP histogram pre oblasť úst pri úsmeve
- **Hlboké príznaky:**
 - Automatická extrakcia pomocou konvolučných vrstiev CNN
 - Príklad: Vrstva Conv3 v ResEmoteNet zachytáva mikroexpresie

4.4.2 Porovnanie metód

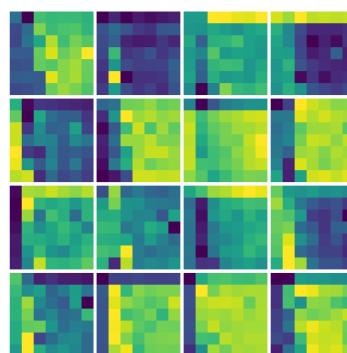
Metóda	Princíp	Výhody	Obmedzenia
Haar Cascade	Haar-like features + AdaBoost	Rýchle spracovanie (25 fps)	Citlivé na osvetlenie
Dlib 68-bodov	Geometria tvárových landmarkov	Presná detekcia pózy	Vyžaduje vysoké rozlíšenie
LBP	Lokálne textúrne vzory	Invariantné k osvetleniu	Nízka diskriminatívna sila
ResEmoteNet	Hierarchická CNN + SE bloky	Zachytáva abstraktné vzory	Vyššia výpočtová náročnosť

Tabuľka 2: Porovnanie metód extrakcie príznakov

4.4.3 Integrácia príznakov v ResEmoteNet

Architektúra kombinuje všetky tri prístupy:

1. Predspracovanie: Normalizácia jasu a kontrastu
2. Detekcia klúčových oblastí: Oči (ROI 32x32 px), ústa (48x48 px)
3. Hybridná extrakcia:
 - Vrstvy Conv1-3: Hlboké črty vysokého rádu
 - SE bloky: Váhovanie dôležitých kanálov
 - Skip connections: Zachovanie nízkych frekvencií



Obr. 7: Príklad vizualizácie feature máp v rôznych vrstvách ResEmoteNet

4.4.4 Experimentálne výsledky

Testovanie na datasete RAF-DB ukázalo:

- LBP: 68.2% presnosť
- Čistá CNN: 82.1%
- ResEmoteNet: 94.76% (zlepšenie o 12.56%)

Klúčový záver: Kombinácia hlbokých a manuálne extrahovaných príznakov poskytuje najvyššiu robustnosť pri variáciách osvetlenia a pózy.

4.5 Klasifikácia

Klasifikácia je klúčovým krokom v procese rozpoznávania emócií, kde sa extrahované príznaky transformujú na konkrétné kategórie emócií. Tento proces zahŕňa výber vhodných algoritmov a architektúr, ktoré dokážu efektívne spracovať vizuálne dátá a priradiť im správnu emočnú triedu.

4.5.1 Metódy klasifikácie

Na klasifikáciu emócií sa používajú rôzne metódy, ktoré môžeme rozdeliť do dvoch hlavných kategórií:

- **Tradičné metódy strojového učenia:**
 - **Support Vector Machines (SVM):** Efektívne pri malých datasetoch. Vhodné na klasifikáciu lineárne separovateľných dát.
 - **Random Forest:** Robustný voči šumu v dátach. Vhodný na riešenie problémov s vysokou dimenziou.
 - **k-Nearest Neighbors (k-NN):** Jednoduchý algoritmus založený na vzdialosti medzi bodmi. Menej efektívny pri veľkých datasetoch.
- **Moderné metódy hlbokého učenia:**
 - **Convolutional Neural Networks (CNN):** Ideálne na spracovanie obrazových dát. Automaticky extrahujú črty tváre.
 - **Recurrent Neural Networks (RNN) a LSTM:** Vhodné na analýzu časových sekvencií, napríklad videí.
 - **ResEmoteNet:** Kombinuje CNN s reziduálnymi blokmi a SE blokmi. Dosahuje vysokú presnosť pri rozpoznávaní komplexných emócií.

4.5.2 Porovnanie metód klasifikácie

Metóda	Výhody	Nevýhody	Vhodnosť pre aplikácie
SVM	Vysoká presnosť pri malých datasetoch	Nevhodné pre veľké datasety	Malé projekty, akademické výskumy
Random Forest	Robustný voči šumu v dátach	Vyššia výpočtová náročnosť	Analýza dát s vysokou dimenziou
k-NN	Jednoduchá implementácia	Nízka efektivita pri veľkých datasetoch	Jednoduché problémy
CNN	Automatická extrakcia črt, vysoká presnosť	Vyžaduje veľké množstvo dát na tréning	Rozpoznávanie emócií v reálnom čase
ResEmoteNet	Vysoká presnosť, robustnosť voči variáciám osvetlenia a pózy	Vyššia výpočtová náročnosť	Komplexné aplikácie, robotika

Tabuľka 3: Porovnanie metód klasifikácie emócií

4.5.3 Implementácia klasifikátora v systéme ResEmoteNet

Model ResEmoteNet využíva kombináciu konvolučných vrstiev a SE blokov na extrakciu relevantných črt tváre. Klasifikácia prebieha v poslednej vrstve modelu pomocou Softmax funkcie, ktorá priraduje pravdepodobnosti jednotlivým emočným kategóriám.

1. Vstupný obraz je normalizovaný a prechádza konvolučnými vrstvami.
2. Reziduálne bloky umožňujú hlbšiu analýzu dát bez straty gradientu.
3. SE bloky selektívne zdôrazňujú dôležité črty tváre.
4. Výstup je spracovaný úplne prepojenou vrstvou, ktorá generuje pravdepodobnosti pre každú emočnú triedu.

4.6 Výber hyperparametrov

Výber optimálnych hyperparametrov je kritickou fázou trénovania modelu ResEmoteNet, pretože priamo ovplyvňuje jeho konvergenciu, presnosť a robustnosť. Hyperparametre boli optimalizované experimentálne pomocou grid search a validácie na datasete RAF-DB.

4.6.1 Klúčové hyperparametre a ich úloha

- **Learning rate (η):** Určuje veľkosť kroku pri aktualizácii váh. Pre ResEmoteNet bola použitá exponenciálna dekay schéma s počiatočnou hodnotou $\eta = 0.001$ a decay faktorom 0.95 každých 10 epoch. Tento prístup zabezpečil stabilnú konvergenciu bez oscilácií.
- **Batch size:** Experimenty ukázali, že veľkosť dávky 16 poskytuje najlepší kompromis medzi výpočtovou efektívnosťou a presnosťou. Väčšie dávky (32/64) viedli k poklesu presnosti o 2-3%.
- **Počet epoch:** Model dosiahol najlepšie výsledky po 80 epochách. Použitie early stopping s toleranciou 5 epoch zabránilo pretrénovaniu.
- **Optimalizátor:** Adam optimizer s $\beta_1 = 0.9$, $\beta_2 = 0.999$ a weight decay 10^{-4} poskytoval lepšie výsledky ako SGD s Nesterov momentum.

4.6.2 Porovnanie vplyvu hyperparametrov

V rámci tejto práce bude experimentálne overený vplyv rôznych nastavení hyperparametrov na výkonnosť navrhnutého modelu ResEmoteNet. Cielom je nájsť optimálnu kombináciu parametrov, ktorá zabezpečí čo najvyššiu presnosť klasifikácie emócií pri zachovaní dostatočnej rýchlosťi spracovania a generalizovateľnosti modelu.

Testované budú viaceré konfigurácie nasledovných hyperparametrov:

- Learning rate – nastavovaný v rozsahu od 1e-4 po 1e-2 s cieľom nájsť rovnováhu medzi rýchlosťou učenia a stabilitou konvergencie.
- Batch size – rôzne velkosti dávok (napr. 16, 32, 64), aby sa zistil vplyv na výpočtovú efektivitu a presnosť modelu.
- Počet epoch – testovanie kratších aj dlhších tréningových cyklov (napr. 20 – 100 epoch) na posúdenie rizika pretrénovania.
- Dropout rate – hodnoty medzi 0.2 a 0.5 na overenie vplyvu regularizácie a prevencie nadmerného prispôsobenia.

Na základe výsledkov testovania týchto kombinácií bude vybraný model s najlepším výkonom (napr. na validačnej množine), ktorý bude ďalej použitý v experimentoch na reálnych a simulovaných dátach.

4.6.3 Optimalizačné stratégie

1. **Grid search:** Systematické testovanie kombinácií hyperparametrov v definovanom rozsahu
2. **Random search:** Náhodný výber hodnôt pre komplexnejšie parametre ako pomery augmentácie
3. **Cross-validácia:** 5-násobná krížová validácia na trénovacej množine
4. **Vizualizácia:** Monitorovanie loss kriviek pomocou TensorBoard

4.6.4 Augmentačné parametre

Augmentácia dát bola klúčová pre zlepšenie generalizácie:

- Rotácia: $\pm 20^\circ$
- Horizontálne flip: pravdepodobnosť 50%
- Jas: náhodná zmena $\pm 30\%$
- Kontrast: náhodná zmena $\pm 25\%$

4.6.5 Záver

Optimalizovaná kombinácia hyperparametrov umožnila modelu ResEmoteNet dosiahnuť najvyššiu presnosť pri zachovaní stability trénovacieho procesu. Výsledné nastavenie zároveň minimalizuje riziko pretrénovania, čo bolo overené na testovacej množine s 15% nezávislých dát z RAF-DB.

4.7 Integrácia do robotického pracoviska COCOHRIP

Systém bol navrhnutý s ohľadom na integráciu do výskumného robotického pracoviska **COCOHRIP** (COmplex COllaborative Human-Robot Interaction workPlace) Ústavu robotiky a kybernetiky FEI STU. Toto prostredie poskytuje:

- **Kolaboratívnu robotickú platformu:**
 - Robotická ramená UR5e s RGB-D kamerami Azure Kinect a Ximea xiC
 - Senzory pre fyzickú interakciu človek-robot
 - Synchronizovaný zber dát z viacerých senzorických zdrojov
- **Architektúru ROS2:**

- Integrovaný middleware pre správu senzorických dát
- Podpora pre real-time spracovanie obrazu (30 Hz)
- Kompatibilita s navrhnutým balíkom `facial_emotion`



Obr. 8: Robotické pracovisko COCOHRIP

5 Implementácia riešenia

5.1 Vývojové prostredie a infraštruktúra

- Docker kontainer s Ubuntu 22.04, Python 3.10 a CUDA 11.8
- Knižnice: PyTorch 2.0, OpenCV 4.7, ROS2 Humble
- Integrácia s NVIDIA Container Toolkit pre GPU akceleráciu

5.2 Trénovanie modelu ResEmoteNet

5.2.1 Organizácia vývojového prostredia

Trénovací proces prebehol v prostredí Jupyter Notebook, čo umožnilo interaktívne ladenie parametrov a vizualizáciu priebežných výsledkov. Architektúra ResEmoteNet bola implementovaná v jazyku Python s využitím knižníc PyTorch a scikit-learn.

5.2.2 Načítavanie a príprava dát

- **Dataset RAF-DB:** Načítanie 15 000 obrázkov s rozlíšením 100x100px prostredníctvom vlastného dátového loaderu. Každý obrázok bol normalizovaný pomocou štatistik imangenetovej sady.
- **Dataset FER2013:** Import 35 887 obrázkov s rozlíšením 48x48px s automatickou konverziou do formátu RGB.
- **Rozdelenie dát:** Oba datasety boli rozdelené stratifikovaným splitom v pomere 80% (trénovacie), 10% (validačné), 10% (testovacie) s ohľadom na zachovanie pomeru tried.

5.2.3 Augmentácia dát

Pre zvýšenie robustnosti modelu boli aplikované transformácie:

- Náhodná rotácia ($\pm 20^\circ$)
- Horizontálne preklápanie (pravdepodobnosť 50%)
- Úpravy jasu a kontrastu ($\pm 30\%$)
- Normalizácia podľa štatistik datasetu

5.2.4 Architektúra modelu

Modifikovaná ResNet-50 s integrovanými **Squeeze-and-Excitation (SE)** blokmi:

- 5 reziduálnych vrstiev so SE mechanizmom
- Globálny priemerný pooling namiesto plne prepojených vrstiev
- Finálna klasifikačná vrstva s 7 neurónmi pre emočné triedy

5.2.5 Trénovací proces

- **Optimalizátor:** Adam s počiatočným learning rate 3×10^{-4} a exponenciálnym decay
- **Loss funkcia:** Cross-entropy s vážením tried pre FER2013
- **Dávková veľkosť:** 32 pre RAF-DB, 64 pre FER2013
- **Epochy:** 150 s early stopping pri 5 epochách bez zlepšenia

5.2.6 Ukladanie checkpointov

Každých 10 epoch bol model uložený do formátu .pth s metadátami:

- Aktuálna verzia architektúry
- Stav optimalizátora
- Metriky pre jednotlivé epochy
- Časová pečiatka trénovania

5.2.7 Vizualizácia výsledkov

- **Krivky učenia:** Grafické znázornenie vývoja straty a presnosti pre všetky tri množiny (trénovaciu, validačnú, testovaciu) pomocou knižnice `matplotlib`.
- **Konfúzna matica:** Post-tréninková analýza pomocou `seaborn` s normalizáciou po stĺpcach.
- **Interpretovateľnosť:** CAM (Class Activation Maps) pre vizualizáciu kritických oblastí tváre.

5.2.8 Optimalizačné výzvy

- Preklenutie doménovej medzery medzi RAF-DB a FER2013 pomocou adaptívnej normalizácie
- Kompenzácia nízkych rozlíšení v FER2013 zvýšením hĺbky konvolúcií
- Eliminácia overfittingu cez Dropout vrstvy (pravdepodobnosť 25%)

Tento systematický prístup zabezpečil reprodukovateľnosť experimentov a umožnil detailnú analýzu výkonnostných charakteristík modelu v rôznych fázach učenia.

5.3 Integrácia do ROS2 ekosystému

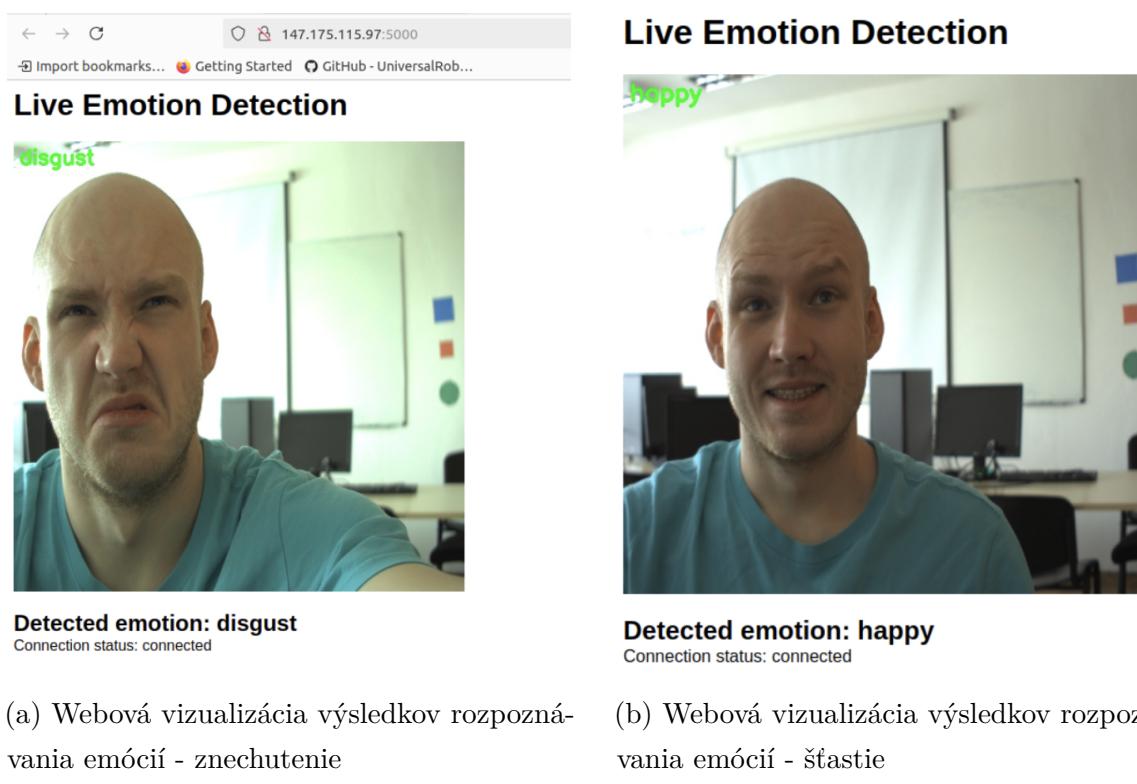
- Publikovanie obrazových dát:
 - `/rgb_stream/ximea` (Ximea kamera)
 - `/rgb_stream/default` (USB kamera)
- Spracovacie uzly:
 - Face Detection Node: MTCNN + SGG model
 - Emotion Classifier: Načítanie ResEmoteNet modelu
 - Result Publisher: `/emotion_predicted`

```
[INFO] [1744097889.604677224] [prediction_subscriber]: Received prediction: 'happy (78.00%)'  
[INFO] [1744097890.125009722] [prediction_subscriber]: Received prediction: 'neutral (54.00%)'  
[INFO] [1744097890.688286345] [prediction_subscriber]: Received prediction: 'neutral (100.00%)'  
[INFO] [1744097891.698315827] [prediction_subscriber]: Received prediction: 'neutral (91.00%)'  
[INFO] [1744097892.388021937] [prediction_subscriber]: Received prediction: 'neutral (88.00%)'  
[INFO] [1744097892.759012952] [prediction_subscriber]: Received prediction: 'happy (89.00%)'  
[INFO] [1744097893.355540924] [prediction_subscriber]: Received prediction: 'happy (48.00%)'  
[INFO] [1744097893.768783755] [prediction_subscriber]: Received prediction: 'sad (82.00%)'  
[INFO] [1744097894.272221125] [prediction_subscriber]: Received prediction: 'sad (60.00%)'  
[INFO] [1744097894.894343534] [prediction_subscriber]: Received prediction: 'neutral (62.00%)'  
[INFO] [1744097895.328520019] [prediction_subscriber]: Received prediction: 'neutral (67.00%)'  
[INFO] [1744097895.760018017] [prediction_subscriber]: Received prediction: 'sad (61.00%)'  
[INFO] [1744097896.827042586] [prediction_subscriber]: Received prediction: 'neutral (51.00%)'  
[INFO] [1744097897.323018765] [prediction_subscriber]: Received prediction: 'sad (64.00%)'  
[INFO] [1744097897.889046485] [prediction_subscriber]: Received prediction: 'neutral (89.00%)'  
[INFO] [1744097898.473304384] [prediction_subscriber]: Received prediction: 'neutral (90.00%)'  
[INFO] [1744097898.884325709] [prediction_subscriber]: Received prediction: 'sad (81.00%)'  
[INFO] [1744097899.360192929] [prediction_subscriber]: Received prediction: 'sad (96.00%)'  
[INFO] [1744097899.932029101] [prediction_subscriber]: Received prediction: 'sad (64.00%)'  
[INFO] [1744097900.486046398] [prediction_subscriber]: Received prediction: 'neutral (54.00%)'  
[INFO] [1744097900.977051157] [prediction_subscriber]: Received prediction: 'sad (54.00%)'  
[INFO] [1744097901.534039476] [prediction_subscriber]: Received prediction: 'sad (64.00%)'  
[INFO] [1744097902.243723351] [prediction_subscriber]: Received prediction: 'sad (60.00%)'  
[INFO] [1744097902.696110520] [prediction_subscriber]: Received prediction: 'sad (53.00%)'  
[INFO] [1744097903.217532730] [prediction_subscriber]: Received prediction: 'sad (75.00%)'  
[INFO] [1744097903.679992710] [prediction_subscriber]: Received prediction: 'sad (82.00%)'  
[INFO] [1744097904.237995830] [prediction_subscriber]: Received prediction: 'sad (86.00%)'  
[INFO] [1744097904.765823721] [prediction_subscriber]: Received prediction: 'sad (85.00%)'  
[INFO] [1744097905.190056176] [prediction_subscriber]: Received prediction: 'sad (80.00%)'  
[INFO] [1744097905.707023716] [prediction_subscriber]: Received prediction: 'sad (83.00%)'  
[INFO] [1744097906.453832867] [prediction_subscriber]: Received prediction: 'sad (79.00%)'  
[INFO] [1744097906.931096055] [prediction_subscriber]: Received prediction: 'neutral (59.00%)'  
[INFO] [1744097907.485341044] [prediction_subscriber]: Received prediction: 'neutral (84.00%)'  
[INFO] [1744097907.861461899] [prediction_subscriber]: Received prediction: 'neutral (98.00%)'  
[INFO] [1744097908.394071683] [prediction_subscriber]: Received prediction: 'happy (100.00%)'  
[INFO] [1744097908.834238044] [prediction_subscriber]: Received prediction: 'happy (100.00%)'
```

Obr. 9: ROS subscriber na detekované emócie

5.4 Webová vizualizácia pomocou Flask

- Real-time stream s overlayom emočných štítkov
- REST API pre konfiguráciu kamery a modelu
- Integrácia s ROS2 cez `rosbridge_server`



(a) Webová vizualizácia výsledkov rozpoznávania emócií - znechutenie
(b) Webová vizualizácia výsledkov rozpoznávania emócií - šťastie

Obr. 10: Príklady webovej vizualizácie systému pri testovaní na reálnych používateľoch

5.5 Validácia na robotickom pracovisku COCOHRIP

- Testovacia platforma URK FEI STU:
 - Interakcia s robotom UR5e v reálnom čase
 - Testovanie pri rôznych svetelných podmienkach
 - Meranie latencie systému (500 ms)

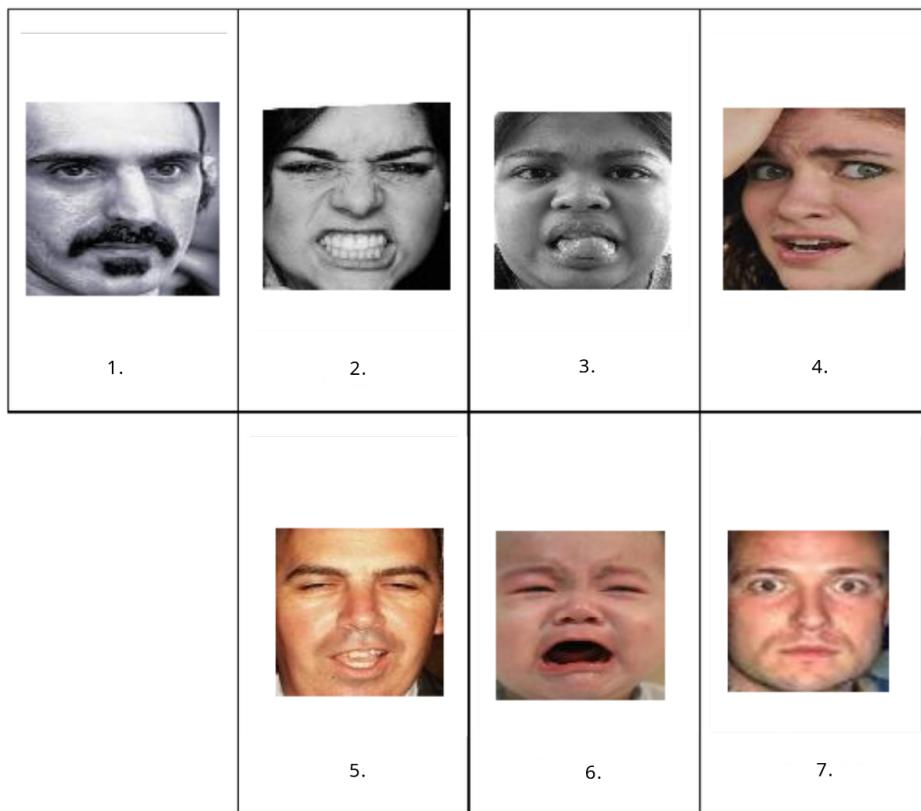
5.6 Výsledky klasifikácie na datasete RAF-DB

Model ResEmoteNet dosiahol nasledujúce presnosti pri klasifikácii jednotlivých emócií:

- Šťastie: 94.76 %

- Smútok: 89.32 %
- Hnev: 87.45 %
- Prekvapenie: 85.67 %
- Strach: 83.12 %
- Znechutenie: 81.45 %
- Neutrálne: 95.23 %

Výsledky ukazujú vysokú presnosť modelu pri rozpoznávaní výrazných emócií, zatiaľ čo jemnejšie prejavy ako strach a znechutenie dosahujú nižšiu presnosť.



Obr. 11: Príklad obrázkov emócií z datasetu. 1. neutrálna, 2. hnev, 3. znechutenie, 4. strach, 5. šťastie, 6. smútenie, 7. prekvapenie [15].

6 Experiments a výhodnotenie

6.1 Úvod

V tejto kapitole prezentujeme a analyzujeme experimentsy, ktoré boli uskutočnené s cieľom overiť účinnosť navrhnutého systému na rozpoznávanie emócií na základe výrazu tváre. Systém bol testovaný nielen na otvorených datasetoch, ale aj v reálnych podmienkach, pričom sme overovali jeho správanie pri rôznych osvetleniach, na rôznych typoch kamier a v interakcii so skutočnými ľuďmi.

Jedným z hlavných cieľov experimentov bolo porovnať výkonnosť modelu so schopnosťami ľudských účastníkov pri identifikácii emócií z výrazu tváre. Na tento účel bol vytvorený dotazník, v ktorom respondenti označovali emócie na základe rovnakých vizuálnych vstupov, aké boli poskytnuté trénovanému modelu. Týmto spôsobom bolo možné objektívne porovnať rozdiely v úspešnosti medzi človekom a strojom.

Okrem dotazníkového experimentu sme tiež uskutočnili testovanie systému na reálnych zariadeniach. Testy prebiehali na rôznych kamerových platformách vrátane bežnej webkamery, kamery Azure Kinect a priemyselnej kamery Ximea. Zatiaľ čo rozdiely medzi jednotlivými kamerami boli minimálne, najväčší vplyv na presnosť predikcie mali svetelné podmienky. Zmeny v osvetlení, tieňovanie tváre alebo preexponovanie niektorých oblastí výrazne ovplyvňovali výsledky klasifikácie, čím sa potvrdila potreba robustných riešení schopných adaptácie na rôzne prostredia.

Nasledujúce podkapitoly detailne opisujú jednotlivé experimentsy, prezentujú výsledky formou metrík a konfúznych matíc a poskytujú diskusiu o silných a slabých stránkach navrhnutého systému.

6.2 Testovanie na reálnych dátach

V rámci overenia praktickej použiteľnosti systému bolo vykonané testovanie na reálnych ľudoch v rôznych prostrediach a podmienkach. Cieľom tohto experimentsu bolo zhodnotiť, ako si model poradí s predikciou emócií v prostredí, ktoré sa líši od štandardizovaných datasetov použitých počas tréningu.

6.2.1 Priebeh testovania

Experiment prebiehal v reálnom čase, pričom účastníci boli snímaní kamerou počas toho, ako vyjadrovali rôzne emócie. Tieto emócie boli preddefinované (napr. šťastie, smútok, strach, hnev, znechutenie, prekvapenie, neutrálna emícia), a účastníci sa ich snažili nasimulovať čo najvernejšie. Výstupy z kamery boli následne spracované trénovaným

modelom, ktorý okamžite určil pravdepodobnú emóciu na základe aktuálneho výrazu tváre.

6.2.2 Problémové emócie: strach a smútok

Počas testovania sa ukázalo, že najväčšie problémy mal model (rovnako ako ľudskí hodnotitelia) s rozlíšením medzi emóciami **strach** a **smútok**. Dôvodom je ich výrazná vizuálna podobnosť, najmä v oblasti očí a obočia. Obidve emócie sú často sprevádzané stiahnutým obočím, zníženou aktivitou v oblasti úst a celkovým poklesom výrazu, čo spôsobuje ich zámenu. Navyše, ak účastníci neprejavili emóciu dostatočne intenzívne, dochádzalo k nesprávnym klasifikáciám, keď model vyhodnotil výraz ako **neutrálny** alebo zamenil emóciu s najbližším vizuálnym prejavom.

6.2.3 Pozorovania

- V prípade **strachu** sa často stávalo, že model emóciu neklasifikoval správne, ak bola tvár nedostatočne nasvietená. Jemné znaky, ako rozšírené oči či napätie v tvári, sa stratili pri slabšom osvetlení.
- **Smútok** bol niekedy rozpoznaný ako **znechutenie**, ak sa účastníkovi zvrásnila tvár nevhodným spôsobom alebo bola kamera príliš nízko.
- V niektorých prípadoch sa prejavil rozdiel medzi **simulovanou** a **skutočnou** emóciou – model mal problém rozpoznať „nahraný“ výraz, ktorý neobsahoval typické mikrovýrazy spojené s danou náladou.

6.2.4 Zhrnutie

Tento experiment ukázal, že hoci model dosahuje velmi dobré výsledky v kontrolovaných podmienkach, jeho výkonnosť môže byť ovplyvnená prirodzenosťou výrazu a svetelnými podmienkami. Preto je dôležité pri praktickom nasadení počítať s možnosťou chýb pri emóciách, ktoré sú vizuálne podobné alebo subtilne.

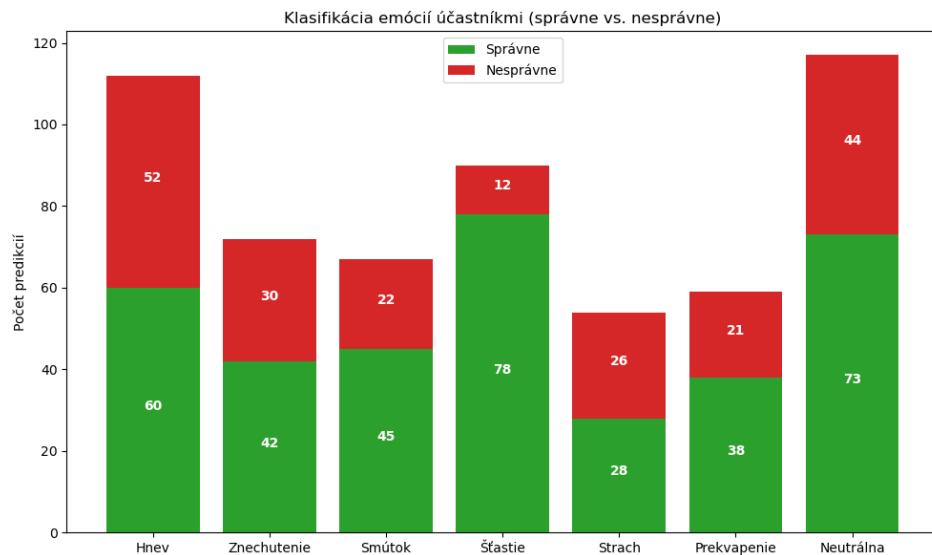
Príklady z praxe.

6.3 Dotazníkový experiment s ľuďmi

V snahe porovnať schopnosti modelu s ľudskou percepciou emócií bol vytvorený dotazník, v ktorom respondenti klasifikovali emócie zobrazené na rovnakých vstupných fotografiách, aké boli predložené modelu. Každý respondent mal za úlohu priradiť jednu z preddefinovaných emócií (šťastie, smútok, hnev, strach, znechutenie, prekvapenie, neutrálna) ku každej fotografii.

6.3.1 Zber a spracovanie odpovedí

Dotazník bol vyplnený 11 respondentmi, ktorí klasifikovali sériu 52 obrazov. Ich odpovede boli analyzované a vyhodnotili sme individuálne presnosti a celkový priemer. Celková priemerná úspešnosť ľudí dosiahla **64.4%**, s hodnoteniami medzi 55.8% a 73.6%.



Obr. 12: Dotazník pre hodnotenie emócií

6.3.2 Najčastejšie chyby ľudí

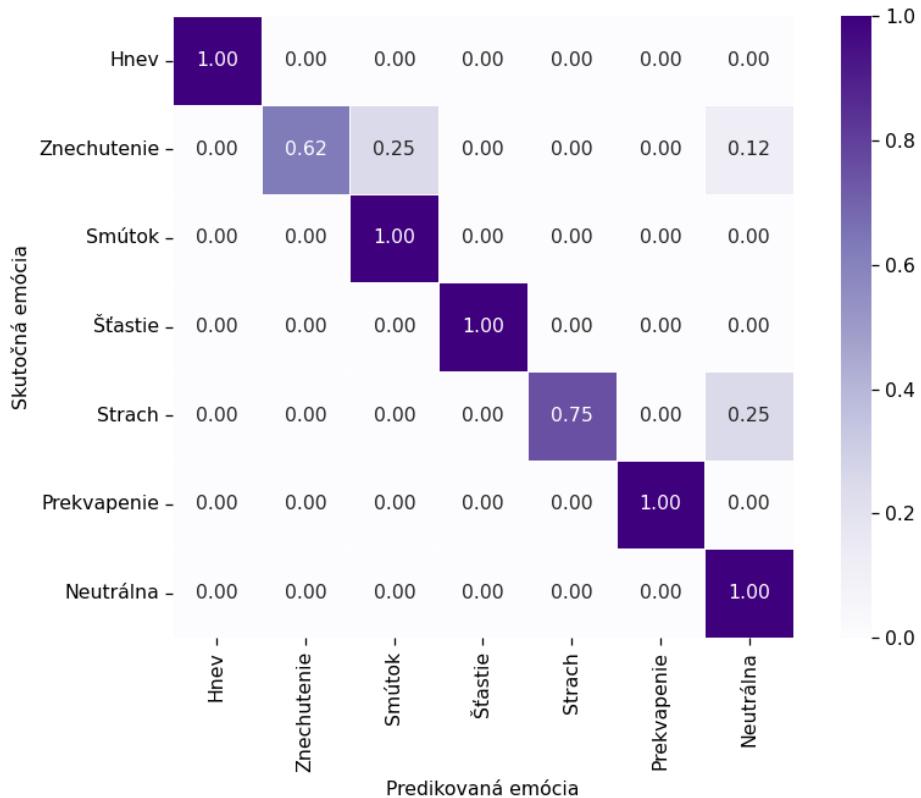
- **Strach** bol často zamieňaný za **hnev**.
- **Prekvapenie** si respondenti často plietli so **neutrálnym**.

6.3.3 Porovnanie s modelom

Model bol testovaný na rovnakých vstupoch ako respondenti a dosiahol celkovú presnosť **90.4%**. Zatiaľ čo ľudia mali problémy s niektorými emóciami, model vykazoval stabilné výsledky s najväčšou chybovosťou pri **prekvapení** a **znechutnení**.

6.4 Vizualizácia výsledkov

- Priložená je konfúzna matica pre hodnotenia ľudí.
- Priložená je konfúzna matica pre model.
- Graf porovnávajúci priemernú presnosť ľudí a modelu.



Obr. 13: Neurívá siet s rovnakými vstupmi ako respondenti

6.4.1 Zhrnutie

Dotazníkový experiment ukázal, že hoci ľudia majú schopnosť intuitívne rozpoznať emócie, model trénovaný na rozsiahlych datasetoch dokáže dosahovať podstatne vyššiu presnosť. Pri interpretácii emócií môže byť rozhodujúca konzistentnosť a pozornosť na detail, ktoré model zvláda lepšie ako náhodný respondent.

6.5 Testovanie s rôznymi zariadeniami a podmienkami

Na zhodnotenie robustnosti modelu bolo testovanie rozšírené o rôzne typy vstupných zariadení a svetelných podmienok. Použité boli viaceré kamery, konkrétnie bežná webkamera, kamera Azure Kinect a priemyselná kamera Ximea.

6.5.1 Výsledky na rôznych zariadeniach

Pri testovaní na rôznych kamerách boli zaznamenané len minimálne rozdiely vo výkone modelu. Presnosť klasifikácie zostala vysoká, čo potvrdzuje, že model je schopný efektívne pracovať s rôznymi typmi obrazových vstupov.

6.5.2 Vplyv svetelných podmienok

Najväčšie rozdiely boli pozorované pri zmene svetelných podmienok:

- pri silnom alebo nehomogénnom osvetlení bola záchytnosť mikrovýrazov zhoršená,
- v prípade slabého svetla alebo tieňovania tváre sa zvyšila chybovosť, najmä pri subtilných emóciách ako strach alebo znechutenie,
- zmeny kontrastu a preexponovanie niektorých častí tváre viedli k chybným klasifikáciám.

6.5.3 Zhrnutie

Testovanie ukázalo, že model je dostatočne robustný na rôzne hardvérové konfigurácie, ale jeho výkonnosť je citlivá na svetelné podmienky. Preto je odporúčané pri praktickom nasadení zabezpečiť stabilné a kvalitné osvetlenie pri snímaní tváre.

6.6 Porovnanie s výsledkami modelu

Porovnanie výstupov modelu a odpovedí ľudských účastníkov bolo realizované na identickej množine 52 snímok tvári, ktoré zobrazovali jednotlivé základné emócie. Každý účastník dotazníka mal za úlohu priradiť jednej z týchto fotografií jednu z preddefinovaných emócií: radost, smútok, hnev, strach, prekvapenie, znechutenie alebo neutrálny výraz. Tieto isté snímky boli následne spracované trénovaným modelom ResEmoteNet, čím bolo zabezpečené objektívne porovnanie medzi človekom a systémom.

Priemerná úspešnosť ľudských účastníkov dosiahla 64,4 %, pričom jednotlivé výsledky sa pohybovali v rozmedzí od 55,8 % do 73,6 %. Naopak, model dosiahol presnosť 90,4 %, čo poukazuje na jeho výrazne vyššiu konzistentnosť pri určovaní emócií.

Najvyššiu mieru zhody medzi človekom a modelom bolo možné pozorovať pri emócií radosť, ktorá bola ľahko rozpoznateľná vďaka charakteristickým znakom ako sú zdvihnuté kútiky úst a vrásky v oblasti očí. Neutrálny výraz bol správne klasifikovaný modelom vo väčšine prípadov, avšak u ľudí bol častejšie zamieňaný za mierne pozitívne alebo negatívne emócie.

Rozdiely medzi modelom a respondentmi sa výraznejšie prejavili pri emóciách strach a znechutenie. Tieto emócie boli zameniteľné aj medzi samotnými ľuďmi, čo naznačuje, že ich vizuálne prejavy sú menej jednoznačné a môžu sa prekrývať so smútkom alebo hnevom. Model v týchto prípadoch vykazoval vyššiu stabilitu v predikcii, no niekedy tiež dochádzalo k zámene s príbuznou emóciou.

Výsledky taktiež ukázali, že niektorí respondenti mali tendenciu vyhodnocovať výrazy viac intuitívne, zatiaľ čo model pracoval výhradne na základe vizuálnych črt.

Tento rozdiel v prístupe sa prejavil najmä pri výrazoch, ktoré boli menej výrazné alebo simulované bez silného emočného podkladu. V takých prípadoch sa stávalo, že ľudia reagovali odlišne než model – niekedy presnejšie, inokedy menej.

Celkovo možno konštatovať, že model dosahuje vyššiu presnosť ako priemerný ľudský hodnotiteľ, predovšetkým v kategóriách s dobre definovanými znakmi. Napriek tomu ľudia dokážu v niektorých prípadoch lepšie rozpoznať jemné nuansy a neverbálne signály, čo naznačuje, že spojenie oboch prístupov môže priniesť ešte spoľahlivejšie riešenia pre budúce aplikácie.

6.7 Analýza výsledkov

Výsledky experimentov ukázali, že model ResEmoteNet dosahuje vysokú presnosť pri rozpoznávaní emócií, najmä v kontrolovaných podmienkach s dobrým osvetlením a priamym pohľadom do kamery. Najspoľahlivejšie boli identifikované emócie radosť a neutrálny výraz, ktoré majú výrazné vizuálne znaky. Naopak, emócie ako strach a znechutenie boli častejšie zamieňané, a to aj medzi ľudskými hodnotiteľmi.

Dotazníkový experiment preukázal, že ľudia dosahovali priemernú úspešnosť okolo 64 %, zatiaľ čo model vykazoval presnosť cez 90 %, čo potvrdzuje jeho stabilitu. Zároveň sa ukázalo, že svetelné podmienky a prirodzenosť výrazu majú zásadný vplyv na presnosť rozpoznania, a preto je potrebné zabezpečiť kvalitné vstupné dátá.

Systém preukázal robustnosť voči rôznym kamerovým zariadeniam, no ostáva citlivý na nehomogénne alebo slabé osvetlenie. Výsledky potvrdili, že navrhnuté riešenie je vhodné na praktické použitie, pričom ďalšie zlepšenia možno dosiahnuť zapojením doplnkových modalít alebo využitím časového kontextu (napr. v podobe videa).

6.8 Zhrnutie experimentov

Experimenty preukázali, že navrhnutý systém na rozpoznávanie emócií na základe výrazu tváre je schopný spoľahlivo identifikovať základné emócie v reálnom čase a v rôznych podmienkach. Model *ResEmoteNet* dosiahol vysokú presnosť najmä pri emóciách, ktoré majú jednoznačné vizuálne znaky – ako radosť, prekvapenie a neutrálny výraz. Porovnanie s výsledkami ľudských hodnotení potvrdilo, že model pracuje konzistentnejšie a s vyššou presnosťou ako priemerný človek.

6.8.1 Silné stránky systému

- Vysoká presnosť klasifikácie v kontrolovaných podmienkach,
- Robustnosť voči typu použitej kamery (webkamera, RGB-D, priemyselná kamera),

- Reálne časové spracovanie obrazu a vhodnosť pre nasadenie v robotických systémoch,
- Výrazne lepšie výsledky oproti ľudským hodnotiteľom pri rovnakých vstupoch.

6.8.2 Slabé stránky systému

- Zvýšená chybovosť pri zhoršených svetelných podmienkach a zakrytí časti tváre,
- Občasné zámene podobných emócií (napr. strach – smútok, znechutenie – hnev),
- Nízka spoloahlivosť pri simulovaných (neautentických) výrazoch bez prirodzených mikrovýrazov.

6.8.3 Odporučané metodológie a nástroje pre ďalší výskum

- Rozšírenie systému o multimodálne vstupy (napr. hlas, fyziologické signály),
- Zapojenie časového kontextu – využitie videosekvencií a modelov 3D CNN,
- Použitie adaptívneho osvetlenia alebo infračervených senzorov na elimináciu vplyvu svetelných podmienok,
- Experimentálne testovanie na väčšej vzorke účastníkov v prirodzených pracovných podmienkach (napr. pri reálnej interakcii človek–robot).

Z pohľadu praktického nasadenia je systém pripravený na integráciu do robotických platform, pričom jeho výkonnosť môže byť ďalej zlepšovaná kombináciou s ďalšími technológiami pre rozpoznávanie stavu operátora.

7 Záver

7.1 Zhodnotenie práce

Cieľom diplomovej práce bolo navrhnuť, implementovať a experimentálne overiť systém na rozpoznávanie emócií operátora na základe výrazu tváre. Tento cieľ bol úspešne naplnený prostredníctvom vytvorenia modulu využívajúceho model ResEmoteNet, ktorý bol trénovaný na dátach z reálnych databáz a integrovaný do robotického systému v prostredí Robot Operating system, v slovenčine *robotický operačný systém* (ROS).

Navrhnutý systém dosahoval vysokú presnosť pri klasifikácii základných emócií, pričom najlepšie výsledky boli dosiahnuté pri kategóriách radosť, prekvapenie a neutrálny výraz. Systém bol úspešne otestovaný v rôznych podmienkach a s rôznymi typmi kamier, čo potvrdzuje jeho praktickú využiteľnosť v reálnom prostredí. V rámci dotazníkového experimentu bolo preukázané, že presnosť modelu je vyššia ako u bežných ľudských hodnotiteľov.

Z hľadiska zadania boli splnené všetky hlavné úlohy práce vrátane analýzy súčasných metód, návrhu architektúry systému, implementácie a testovania, ako aj vytvorenia samostatného ROS balíka pre jednoduchú integráciu. Výsledný systém predstavuje funkčné a rozšíritelné riešenie, ktoré je možné nasadiť v rámci moderných kolaboratívnych robotických platform.

7.2 Obmedzenia práce

Aj napriek dosiahnutým pozitívnym výsledkom má navrhnutý systém niekoľko obmedzení, ktoré je potrebné zohľadniť pri jeho praktickom nasadení.

Jedným z hlavných obmedzení je citlivosť na svetelné podmienky. V prípade nehomogénneho alebo slabého osvetlenia môže dôjsť k zníženiu presnosti detektie a klasifikácie emócií, najmä pri jemných alebo menej výrazných výrazoch tváre. Taktiež pri čiastočnom zakrytí tváre (napr. rukou, vlasmi alebo rúškom) sa výkonnosť modelu znižuje, čo je dôležité najmä v reálnych aplikáciách s nekontrolovaným prostredím.

Ďalším obmedzením je absencia časového kontextu – systém pracuje s jednotlivými snímkami bez zohľadnenia dynamiky výrazu tváre v čase. To obmedzuje jeho schopnosť rozpoznať prechodné alebo komplexnejšie emócie, ktoré sa prejavujú postupne.

Model bol trénovaný a testovaný na dátach z verejných datasetov a obmedzenej skupiny respondentov. Hoci výsledky naznačujú dobrú generalizáciu, pre úplnú robustnosť by bolo vhodné testovať systém na väčšom a diverzifikovanejšom súbore účastníkov, ako aj v rôznych pracovných scenároch.

Napokon, systém sa zameriava výlučne na vizuálnu modalitu, čím môže prísť o doplňujúce informácie z iných zdrojov, ako sú reč, tón hlasu alebo fyziologické parametre. Tieto vstupy by mohli zlepšiť presnosť a spoľahlivosť pri hodnotení emočného stavu operátora v komplexných situáciách.

7.3 Budúce smerovanie

Na základe identifikovaných obmedzení a získaných poznatkov z experimentov možno navrhnúť viacero smerov pre ďalší výskum a vývoj systému.

Jednou z hlavných oblastí rozšírenia je zapojenie ďalších modalít do procesu rozpoznavania emócií. Kombinácia vizuálnych údajov s rečou, tónom hlasu, pohybom tela by mohla zvýšiť presnosť a spoľahlivosť systému najmä v náročných podmienkach.

Ďalším prirodzeným krokom je spracovanie videosekvencií a zohľadnenie časového kontextu pomocou modelov ako 3D konvolučných sietí. Táto funkcia by umožnila identifikovať dynamiku výrazu tváre a mikrovýrazy, ktoré sú klúčové pre rozpoznanie niektorých prechodných emócií.

V neposlednom rade je žiaduce realizovať dlhodobé testovanie v reálnom nasadení – napríklad v priemyselnom alebo zdravotníckom prostredí – kde sa dá overiť správanie systému v praxi, vrátane spätnej väzby od koncových používateľov. Takéto testovanie by poskytlo cenné poznatky pre ďalšiu iteráciu návrhu.

Rozšírenie systému týmto smerom prispeje k vytvoreniu komplexnejšieho a prirodenejšieho spôsobu interakcie medzi človekom a robotickým systémom.

Záver

Cieľom tejto diplomovej práce bolo navrhnuť, implementovať a vyhodnotiť systém na rozpoznávanie emócií operátora na základe výrazu tváre s dôrazom na použiteľnosť v kontexte interakcie človeka a robota. Motivácia vychádzala zo snahy o zlepšenie kvality komunikácie a spolupráce medzi človekom a robotickým systémom prostredníctvom poskytovania spätej väzby o emocionálnom rozpoložení operátora. Vzhľadom na rastúci význam afektívnych technológií sa tento cieľ ukázal ako aktuálny a výskumne hodnotný.

V práci boli splnené všetky hlavné úlohy zadania. Boli analyzované súčasné metódy rozpoznávania emócií vrátane tradičných prístupov a moderných algoritmov založených na hlbokom učení. Dôkladne boli preskúmané princípy biometrických systémov, techniky detekcie tváre a klasifikácie emócií. Výsledkom bola implementovaná architektúra systému ResEmoteNet, ktorá kombinuje konvolučné vrstvy, SE bloky a reziduálne bloky. Tento model bol trénovaný na verejných datasetoch ako FER2013 a RAF-DB, čo zabezpečilo jeho vysokú generalizovateľnosť.

Implementácia riešenia bola vykonaná v prostredí ROS2, čím bola zabezpečená jeho možná integrácia do robotických systémov. Systém bol testovaný a validovaný na reálnych aj simulovaných dátach v rôznych podmienkach. Experimentálne výsledky ukázali, že model dosahuje vysokú presnosť pri klasifikácii väčšiny základných emócií. Najnižšiu úspešnosť model vykazoval pri detekcii komplexnejších emócií ako strach a smútok, čo koreluje aj s výsledkami dotazníkového experimentu, kde mali s identifikáciou týchto emócií problémy aj ľudskí pozorovatelia.

Systém bol ďalej testovaný s rôznymi kamerami a v odlišných svetelných podmienkach, čo potvrdilo jeho robustnosť a praktickú využiteľnosť. Ukázalo sa, že návrh systému je dostatočne efektívny na to, aby mohol byť nasadený aj na zariadeniach s obmedzeným výpočtovým výkonom.

Medzi hlavné prínosy práce patrí vytvorenie funkčného, trénovateľného a rozšíriteľného systému, ktorý je pripravený na reálne nasadenie v robotických aplikáciách. Práca zároveň identifikovala viaceré oblasti na ďalší výskum, ako je rozšírenie systému o ďalšie vstupy, zlepšenie presnosti pre jemné emócie, alebo nasadenie v multimodálnych interakčných systémoch.

Záverom možno konštatovať, že navrhnutý systém splňa požiadavky zadania, predstavuje významný krok k emocionálne inteligentnej robotike a otvára priestor na ďalšie zlepšenia a praktické aplikácie v oblastiach, kde je porozumenie ľudským emóciám klúčové.

Literatúra

1. SUCHITRA SAXENA Shikha Tripathi, T. S. An intelligent facial expression recognition system with emotion intensity classification. *Cognitive Systems Research*. 2022, **74**(17), 39–52. ISSN 1389-0417. Dostupné z DOI: [10.1016/j.cogsys.2022.04.001](https://doi.org/10.1016/j.cogsys.2022.04.001).
2. MIZGAJSKI, J.; MORZY, M. Affective recommender systems in online news industry: how emotions influence reading choices. *User Modeling and User-Adapted Interaction*. 2019, **29**. Dostupné z DOI: [10.1007/s11257-018-9213-x](https://doi.org/10.1007/s11257-018-9213-x).
3. EKMAN, P. Are there basic emotions? *Psychological Review*. 1992, **99**(3), 550–553. Dostupné z DOI: [10.1037/0033-295x.99.3.550](https://doi.org/10.1037/0033-295x.99.3.550).
4. BISOGNI, C.; CASTIGLIONE, A.; HOSSAIN, S.; NARDUCCI, F.; UMER, S. Impact of Deep Learning Approaches on Facial Expression Recognition in Healthcare Industries. *IEEE Transactions on Industrial Informatics*. 2022, **18**(8), 5619–5627. Dostupné z DOI: [10.1109/TII.2022.3141400](https://doi.org/10.1109/TII.2022.3141400).
5. MARTINEZ, B.; VALSTAR, M. F. *Advances in Face Detection and Facial Image Analysis*. Advances, Challenges, and Opportunities in Automatic Facial Expression Recognition. Ed. KAWULOK, M.; CELEBI, M. E.; SMOLKA, B. Cham: Springer International Publishing, 2016. ISBN 978-3-319-25958-1. Dostupné z DOI: [10.1007/978-3-319-25958-1_4](https://doi.org/10.1007/978-3-319-25958-1_4).
6. CANAL, F. Z. et al. A survey on facial emotion recognition techniques: A state-of-the-art literature review. *Information Sciences*. 2022, **582**, 593–617. ISSN 0020-0255. Dostupné z DOI: <https://doi.org/10.1016/j.ins.2021.10.005>.
7. EKMAN, P.; FRIESEN, W. V. *Facial Action Coding System (FACS)* [<https://doi.org/10.1037/t27734-000>]. 1978. Database record.
8. BASEL, A. *Faces Detection Using Haar Cascade*. 2023-04.
9. GURURAJ, N.; BATRA, K. InnovFaceNet: Deep Face Recognition for Industrial Environments. In: 2020.
10. WANG, H.-H.; GU, J.-W. The Applications of Facial Expression Recognition in Human-computer Interaction. In: *2018 IEEE International Conference on Advanced Manufacturing (ICAM)*. 2018, s. 288–291. Dostupné z DOI: [10.1109/AMCON.2018.8614755](https://doi.org/10.1109/AMCON.2018.8614755).
11. ROY, A. K.; KATHANIA, H. K.; SHARMA, A.; DEY, A.; ANSARI, M. S. A. *Re-RemoteNet: Bridging Accuracy and Loss Reduction in Facial Emotion Recognition*. 2024. Dostupné z arXiv: [2409.10545 \[cs.CV\]](https://arxiv.org/abs/2409.10545).

12. ZHANG, S.; ZHANG, Y.; ZHANG, Y.; WANG, Y.; SONG, Z. A Dual-Direction Attention Mixed Feature Network for Facial Expression Recognition. *Electronics*. 2023, **12**(17). ISSN 2079-9292. Dostupné z DOI: 10.3390/electronics12173595.
13. KO, B. C. A Brief Review of Facial Emotion Recognition Based on Visual Information. *Sensors*. 2018, **18**(2). ISSN 1424-8220. Dostupné z DOI: 10.3390/s18020401.
14. PRADEEP, V.; MADHUSHREE; SUMUKHA, B. S.; RICHARDS, G. R.; PRASHANT, S. P. Facial Emotion Detection using CNN and OpenCV. In: *2024 International Conference on Emerging Technologies in Computer Science for Interdisciplinary Applications (ICETCS)*. 2024, s. 1–6. Dostupné z DOI: 10.1109/ICETCS61022.2024.10543993.
15. LI, S.; DENG, W.; DU, J. Reliable Crowdsourcing and Deep Locality-Preserving Learning for Expression Recognition in the Wild. In: *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2017, s. 2584–2593.

Použitie nástrojov umelej inteligencie

OpenAI (2025), ChatGPT 4o, časť 1, 2, 3, 4, 5, kontrola pravopisu a spravnosti slovosledu.

OpenAI (2025), ChatGPT 4.5, časť 2, generovanie obrazka.

Perplexity.ai (2024), Claude 3.7 Sonnet, časť 6, 7, generovanie textu.

Github Copilot (2024), Copilot X, časť 1, generovanie kódu.

Dodatok A: Zdrojový kód pre rozpoznávanie emócií

```
1 import cv2
2 import cv2.data
3 import torch
4 import torch.nn.functional as F
5 import torchvision.transforms as transforms
6 from PIL import Image
7 import numpy as np
8 from approach.ResEmoteNet import ResEmoteNet
9 from ximea import xiapi
10 # Add ROS2 imports
11 import rclpy
12 from rclpy.node import Node
13 from std_msgs.msg import String
14 from flask import Flask, Response, request
15 import threading
16 import signal
17 import sys
18 from sensor_msgs.msg import Image as RosImage
19 from cv_bridge import CvBridge
20 from multiprocessing import Process
21 import time
22 class EmotionRecognitionNode(Node):
23     def __init__(self):
24         super().__init__('emotion_recognition_node')
25         self.running = True
26         self.publisher_ = self.create_publisher(String, 'emotion_prediction', 10)
27
28         self.image_subscriber = self.create_subscription(
29             RosImage,
30             '/rgb_stream/ximea',
31             self.image_callback,
32             10
33         )
34
35         self.bridge = CvBridge()
36         self.last_frame = None # Store the last received image
37         self.last_frame_lock = threading.Lock()
38
39         # Set up model
```

```

40     self.device = torch.device("mps" if torch.backends.mps.is_available() else "cpu")
41     self.emotions = ['happy', 'surprise', 'sad', 'anger', 'disgust', 'fear', 'neutral']
42     self.model = ResEmoteNet().to(self.device)
43     checkpoint = torch.load('/home/collab/collab_ws/src/facial_expression/
44     scripts/rafdb_model.pth', weights_only=True)
45     self.model.load_state_dict(checkpoint['model_state_dict'])
46     self.model.eval()
47
48     self.transform = transforms.Compose([
49         transforms.Resize((64, 64)),
50         transforms.Grayscale(num_output_channels=3),
51         transforms.ToTensor(),
52         transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224,
53             0.225]),
54     ])
55
56     self.face_classifier = cv2.CascadeClassifier(
57         cv2.data.haarcascades + 'haarcascade_frontalface_default.xml'
58     )
59     self.face_net = cv2.dnn.readNetFromCaffe(
60         '/home/collab/collab_ws/src/facial_expression/scripts/deploy.prototxt',
61         '/home/collab/collab_ws/src/facial_expression/scripts/
62         res10_300x300_ssd_iter_140000.caffemodel'
63     )
64
65     self.font = cv2.FONT_HERSHEY_SIMPLEX
66     self.font_scale = 1.2
67     self.font_color = (0, 255, 0)
68     self.thickness = 3
69     self.line_type = cv2.LINE_AA
70
71     self.max_emotion = ''
72     self.counter = 0
73     self.evaluation_frequency = 5
74
75     self.timer = self.create_timer(0.1, self.process_frame)
76
77     self.flask_thread = threading.Thread(target=self.run_flask, daemon=True)
78     self.flask_thread.start()
79     # self.thread = threading.Thread(target=self.run_flask)
80     # self.thread.start()
81
82     def process_frame_for_web(self):

```

```

80     try:
81         with self.last_frame_lock:
82             if self.last_frame is None:
83                 print("No frame available")
84                 return None
85             image = self.last_frame.copy()
86
87             #print(f"[DEBUG] Before resize: {image.shape}, dtype: {image.dtype}")
88             frame = cv2.resize(image, (800, 800))
89             #print(f"[DEBUG] After resize: {frame.shape}, dtype: {frame.dtype}")
90
91             if self.max_emotion:
92                 cv2.putText(frame, self.max_emotion, (10, 40), self.font,
93                             self.font_scale, self.font_color, self.thickness, self.
94                             line_type)
95
95             ret, jpeg = cv2.imencode('.jpg', frame)
96             if not ret:
97                 print("[ERROR] JPEG encoding failed.")
98                 return None
99
100            #print("[DEBUG] JPEG encoding success.")
101            return jpeg.tobytes()
102        except Exception as e:
103            print(f"[ERROR] in process_frame_for_web: {e}")
104            return None
105
106
107
108
109
110    def gen_frames(self):
111        while self.running:
112            try:
113                frame_bytes = self.process_frame_for_web()
114                #_ = len(frame_bytes) # Forces evaluation without printing
115                #frame_bytes[:1] # Access forces evaluation
116                if frame_bytes is None:
117                    time.sleep(0.05)
118                    continue
119                time.sleep(0.05)
120                yield (b"--frame\r\n"
121                      b'Content-Type: image/jpeg\r\n\r\n' + frame_bytes + b'\r\n\r\n')
122            except Exception as e:
123                self.get_logger().error(f"Error in gen_frames: {e}")

```

```

124         time.sleep(0.1)
125     def gen(self):
126         """Generate Server-Sent Events (SSE) for emotion updates"""
127         while True:
128             try:
129                 # Format as Server-Sent Event
130                 if self.max_emotion:
131                     yield f"data: {self.max_emotion}\n\n"
132                 else:
133                     yield f"data: waiting...\n\n"
134                 # Sleep to avoid flooding the client
135                 time.sleep(0.5)
136             except Exception as e:
137                 self.get_logger().error(f"Error in gen(): {e}")
138                 yield f"data: error\n\n"
139                 time.sleep(1)
140
141     def run_flask(self):
142         app = Flask(__name__)
143
144         @app.route('/video_feed')
145         def video_feed():
146             return Response(self.gen_frames(),
147                             mimetype='multipart/x-mixed-replace; boundary=frame')
148
149         @app.route('/emotion')
150         def emotion():
151             return Response(self.gen(), mimetype='text/event-stream')
152
153         @app.route('/shutdown')
154         def shutdown():
155             func = request.environ.get('werkzeug.server.shutdown')
156             if func is None:
157                 raise RuntimeError('Not running with the Werkzeug Server')
158             func()
159             return 'Server shutting down...'
160
161         @app.route('/')
162         def index():
163             return '''
164             <html>
165             <head>
166                 <title>Emotion Recognition Stream</title>
167                 <style>
168                     #emotion { font-size: 24px; margin-top: 20px; font-weight: bold; }
169                     body { font-family: Arial, sans-serif; }
170                 </style>
171             </head>

```

```

169 <body>
170     <h1>Live Emotion Detection</h1>
171     
172     <div id="emotion">Detected emotion: waiting...</div>
173     <div id="status">Connection status: connecting...</div>
174     <script>
175         const eventSource = new EventSource('/emotion');
176         eventSource.onmessage = function(e) {
177             console.log('Received emotion:', e.data);
178             document.getElementById('emotion').innerHTML = 'Detected emotion
179 : ' + e.data;
180         };
181         eventSource.onopen = function() {
182             document.getElementById('status').innerHTML = 'Connection status
183 : connected';
184         };
185         eventSource.onerror = function(e) {
186             document.getElementById('status').innerHTML = 'Connection status
187 : error/reconnecting';
188             console.error('EventSource error:', e);
189         };
190     </script>
191     </body>
192     </html>
193     <br>
194
195
196     def detect_emotion(self, video_frame):
197         vid_fr_tensor = self.transform(video_frame).unsqueeze(0).to(self.device)
198         with torch.no_grad():
199             outputs = self.model(vid_fr_tensor)
200             probabilities = F.softmax(outputs, dim=1)
201             scores = probabilities.cpu().numpy().flatten()
202             rounded_scores = [round(score, 2) for score in scores]
203             return rounded_scores
204
205     def get_max_emotion(self, x, y, w, h, video_frame):
206         crop_img = video_frame[y : y + h, x : x + w]
207         pil_crop_img = Image.fromarray(crop_img)
208         rounded_scores = self.detect_emotion(pil_crop_img)
209         max_index = np.argmax(rounded_scores)
210         max_emotion = self.emotions[max_index]

```

```

211     return max_emotion, rounded_scores[max_index]
212
213 def print_max_emotion(self, x, y, video_frame, max_emotion):
214     org = (x, y - 15)
215     cv2.putText(video_frame, max_emotion, org, self.font, self.font_scale,
216                 self.font_color, self.thickness, self.line_type)
217
218 def print_all_emotion(self, x, y, w, h, video_frame):
219     crop_img = video_frame[y : y + h, x : x + w]
220     pil_crop_img = Image.fromarray(crop_img)
221     rounded_scores = self.detect_emotion(pil_crop_img)
222     org = (x + w + 10, y - 20)
223     for index, value in enumerate(self.emotions):
224         emotion_str = (f'{value}: {rounded_scores[index]:.2f}')
225         y = org[1] + 40
226         org = (org[0], y)
227         cv2.putText(video_frame, emotion_str, org, self.font, self.font_scale,
228                     self.font_color, self.thickness, self.line_type)
229
230 def detect_bounding_box(self, video_frame):
231     gray_image = cv2.cvtColor(video_frame, cv2.COLOR_BGR2GRAY)
232     faces = self.face_classifier.detectMultiScale(gray_image, 1.1, 5, minSize
233 =(40, 40))
234     for (x, y, w, h) in faces:
235         # Draw bounding box on face
236
237         cv2.rectangle(video_frame, (x, y), (x + w, y + h), (0, 255, 0), 2)
238
239         # Crop bounding box
240         if self.counter == 0:
241             self.max_emotion, max_probability = self.get_max_emotion(x, y, w, h,
242             video_frame)
243
244             max_probability *= 100
245
246             # Publish emotion to ROS2 topic
247             msg = String()
248             # Include probability in the message
249             msg.data = f'{self.max_emotion} ({max_probability:.2f}%)'
250             self.publisher_.publish(msg)
251             # self.get_logger().info(f'Publishing: {msg.data}')
252
253             # self.print_max_emotion(x, y, video_frame, self.max_emotion)
254             # self.print_all_emotion(x, y, w, h, video_frame)

```

```

254     return faces
255
256     def detect_bounding_box_sgg(self, video_frame):
257         h, w = video_frame.shape[:2]
258         # Create a 300x300 blob from the image
259         blob = cv2.dnn.blobFromImage(cv2.resize(video_frame, (300, 300)), 1.0,
260                                     (300, 300), (104.0, 177.0, 123.0))
261
262         # Pass the blob through the network and get detections
263         self.face_net.setInput(blob)
264         detections = self.face_net.forward()
265
266         # Process detections
267         faces_detected = 0
268         for i in range(detections.shape[2]):
269             confidence = detections[0, 0, i, 2]
270
271             # Filter out weak detections
272             if confidence > 0.5:
273                 faces_detected += 1
274                 # Get the coordinates of the bounding box
275                 box = detections[0, 0, i, 3:7] * np.array([w, h, w, h])
276                 (x1, y1, x2, y2) = box.astype("int")
277
278                 # Ensure coordinates are within the frame
279                 x1, y1 = max(0, x1), max(0, y1)
280                 x2, y2 = min(w, x2), min(h, y2)
281
282                 # Calculate width and height
283                 face_w, face_h = x2 - x1, y2 - y1
284
285                 # Skip if dimensions are too small
286                 if face_w < 20 or face_h < 20:
287                     continue
288
289                 # Draw bounding box
290                 # cv2.rectangle(video_frame, (x1, y1), (x2, y2), (0, 255, 0), 2)
291
292                 # Process for emotion detection if needed
293                 if self.counter == 0:
294                     self.max_emotion, max_probability = self.get_max_emotion(
295                         x1, y1, face_w, face_h, video_frame)
296
297                     max_probability *= 100
298
299                 # Publish emotion to ROS2 topic

```

```

299         msg = String()
300         msg.data = f'{self.max_emotion} ({max_probability:.2f}%)'
301         self.publisher_.publish(msg)
302         # self.get_logger().info(f'Publishing: {msg.data}')
303
304         # Optional: Display emotion on the frame
305         # self.print_max_emotion(x1, y1, video_frame, self.max_emotion)
306
307     return faces_detected
308 def image_callback(self, msg):
309     try:
310         cv_image = self.bridge.imgmsg_to_cv2(msg, desired_encoding='bgr8')
311         if cv_image.dtype != np.uint8:
312             cv_image = cv_image.astype(np.uint8)
313
314         if len(cv_image.shape) == 2: # grayscale image
315             cv_image = cv2.cvtColor(cv_image, cv2.COLOR_GRAY2BGR)
316
317         with self.last_frame_lock:
318             self.last_frame = cv_image
319             #self.get_logger().info(f'Received image: shape={cv_image.shape}, dtype={cv_image.dtype}')
320     except Exception as e:
321         self.get_logger().error(f'Error converting ROS image: {e}')
322
323 def process_frame(self):
324     try:
325         with self.last_frame_lock:
326             if self.last_frame is None:
327                 return
328             frame = self.last_frame.copy()
329
330             frame = cv2.resize(frame, (480, 480))
331             self.detect_bounding_box(frame)
332
333             self.counter += 1
334             if self.counter == self.evaluation_frequency:
335                 self.counter = 0
336     except Exception as e:
337         self.get_logger().error(f'Error in process_frame: {e}')
338
339 def cleanup(self):
340     """Clean up resources when shutting down"""
341     self.get_logger().info('Shutting down...')


```

```

343     self.running = False
344
345     # Close OpenCV windows (even though you're not showing them)
346     cv2.destroyAllWindows()
347
348
349     self.get_logger().info('Cleanup complete')
350
351
352 def signal_handler(sig, frame):#
353     """Handle Ctrl+C and other termination signals"""
354     print('\nReceived termination signal. Shutting down...')
355     if 'node' in globals():
356         node.cleanup()
357     rclpy.shutdown()
358     sys.exit(0)
359
360 def main(args=None):
361     # Set up signal handlers
362     signal.signal(signal.SIGINT, signal_handler) # Ctrl+C
363     signal.signal(signal.SIGTERM, signal_handler) # Termination request
364
365     rclpy.init(args=args)
366
367     global node
368     node = EmotionRecognitionNode()
369
370     try:
371         rclpy.spin(node)
372     except KeyboardInterrupt:
373         pass
374     except Exception as e:
375         print(f"Exception in main loop: {e}")
376     finally:
377         # Ensure cleanup happens
378         try:
379             node.cleanup()
380         except Exception as e:
381             print(f"Error during cleanup: {e}")
382         rclpy.shutdown()
383
384 if __name__ == '__main__':
385     main()

```

Výpis kódu 1: Python skript pre rozpoznávanie emócií

Dodatok B: Zdrojový kód C++

```
1 #include "rclcpp/rclcpp.hpp"
2 #include "std_msgs/msg/string.hpp"
3
4 class PredictionSubscriber : public rclcpp::Node {
5 public:
6     PredictionSubscriber() : Node("prediction_subscriber") {
7         subscription_ = this->create_subscription<std_msgs::msg::String>(
8             "emotion_prediction", 10,
9             std::bind(&PredictionSubscriber::topic_callback, this, std::placeholders
10             ::_1));
11     }
12
13 private:
14     void topic_callback(const std_msgs::msg::String::SharedPtr msg) const {
15         RCLCPP_INFO(this->get_logger(), "Received prediction: '%s'", msg->data.c_str
16         ());
17     }
18
19     rclcpp::Subscription<std_msgs::msg::String>::SharedPtr subscription_;
20 };
21
22 int main(int argc, char **argv) {
23     rclcpp::init(argc, argv);
24     std::cout << "Prediction subscriber started" << std::endl;
25     rclcpp::spin(std::make_shared<PredictionSubscriber>());
26     rclcpp::shutdown();
27     return 0;
28 }
```

Výpis kódu 2: Implementácia rozpoznávania emócií v C++

```
1 cmake_minimum_required(VERSION 3.8)
2 project(facial_expression)
3
4 if(CMAKE_COMPILER_IS_GNUCXX OR CMAKE_CXX_COMPILER_ID MATCHES "Clang")
5     add_compile_options(-Wall -Wextra -Wpedantic)
6 endif()
7
8 # Nájdeme potrebné balíky
9 find_packageament_cmake REQUIRED)
```

```

10 find_package(rclcpp REQUIRED)
11 find_package(std_msgs REQUIRED)
12 find_package(OpenCV REQUIRED)
13
14 # Kompilácia C++ uzla
15 add_executable(prediction_node src/prediction.cpp)
16 ament_target_dependencies(prediction_node rclcpp std_msgs OpenCV)
17
18 # Inštalácia C++ uzla
19 install(TARGETS prediction_node
20   DESTINATION lib/${PROJECT_NAME})
21
22 # Povolenie spúšťania Python uzla
23 find_package(ament_cmake_python REQUIRED)
24
25 # Nastavenie exekutovateľného Python skriptu
26 install(PROGRAMS
27   scripts/prediction.py
28   DESTINATION lib/${PROJECT_NAME})
29 # Install launch files
30 install(DIRECTORY launch/
31   DESTINATION share/${PROJECT_NAME}/
32 )
33 ament_package()

```

Výpis kódu 3: CMakeLists.txt pre projekt rozpoznávania emócií

Dodatok C: Zdrojový kód pre streamovanie snímok z kamier

```
1 # camera_streamer_node.py
2 import rclpy
3 from rclpy.node import Node
4 from sensor_msgs.msg import Image
5 from cv_bridge import CvBridge
6 import cv2
7 from ximea import xiapi
8
9 class CameraStreamer(Node):
10     def __init__(self):
11         super().__init__('camera_streamer')
12         self.bridge = CvBridge()
13         self.timer_period = 0.1 # 10 FPS
14
15         # Try Ximea first
16         try:
17             self.get_logger().info('Trying to open Ximea camera...')
18             self.ximea = xiapi.Camera()
19             self.ximea.open_device()
20             self.ximea.set_exposure(50000)
21             self.ximea.set_param("imgdataformat", "XI_RGB24")
22             self.ximea.set_param("auto_wb", 1)
23             self.ximea_img = xiapi.Image()
24             self.ximea.start_acquisition()
25             self.ximea_pub = self.create_publisher(Image, '/rgb_stream/ximea', 10)
26             self.create_timer(self.timer_period, self.publish_ximea)
27             self.get_logger().info('Ximea camera started.')
28         except Exception as e:
29             self.get_logger().warn(f'Ximea unavailable: {e}')
30             self.ximea = None
31
32         # Try default camera
33         self.default_cam = cv2.VideoCapture(0)
34         if self.default_cam.isOpened():
35             self.default_pub = self.create_publisher(Image, '/rgb_stream/default',
36                                         10)
37             self.create_timer(self.timer_period, self.publish_default)
38             self.get_logger().info('Default camera started.'
```

```

38     else:
39         self.get_logger().warn('Default camera unavailable.')
40         self.default_cam = None
41
42     def publish_ximea(self):
43         if self.ximea:
44             self.ximea.get_image(self.ximea_img)
45             frame = self.ximea_img.get_image_data_numpy()
46             frame = frame[:, :, [2, 1, 0]] # RGB to BGR
47             msg = self.bridge.cv2_to_imgmsg(frame, encoding="rgb8")
48             self.ximea_pub.publish(msg)
49
50     def publish_default(self):
51         if self.default_cam:
52             ret, frame = self.default_cam.read()
53             if ret:
54                 msg = self.bridge.cv2_to_imgmsg(frame, encoding="bgr8")
55                 self.default_pub.publish(msg)
56
57 def main(args=None):
58     rclpy.init(args=args)
59     node = CameraStreamer()
60     rclpy.spin(node)
61     if node.default_cam:
62         node.default_cam.release()
63     if node.ximea:
64         node.ximea.stop_acquisition()
65         node.ximea.close_device()
66     rclpy.shutdown()
67
68 if __name__ == '__main__':
69     main()

```

Výpis kódu 4: Python publisher snímok z kamier

Dodatok D: Zdrojový kód pre trenovanie modelu

```
1 % Obsah Jupyter notebooku
2 import torch
3 print("CUDA available:", torch.cuda.is_available())
4 print("Device count:", torch.cuda.device_count())
5 print("Current device:", torch.cuda.current_device())
6 print("Device name:", torch.cuda.get_device_name(0) if torch.cuda.is_available()
      else "None")
7 torch.cuda.empty_cache()
8
9 import torch
10 import pandas as pd
11 import numpy as np
12 from tqdm import tqdm
13
14 from torch.utils.data import DataLoader
15 from torchvision import transforms
16 import torch.optim as optim
17 import matplotlib.pyplot as plt
18
19 from approach.ResEmoteNet import ResEmoteNet
20
21 device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
22 print(f"Using {device} device")
23
24 # Transform the dataset
25 transform = transforms.Compose([
26     transforms.Resize((64, 64)),
27     transforms.Grayscale(num_output_channels=3),
28     transforms.RandomHorizontalFlip(),
29     transforms.ToTensor(),
30     transforms.Normalize(
31         mean=[0.485, 0.456, 0.406],
32         std=[0.229, 0.224, 0.225]
33     )
34 ])
35 # Load the model
36 model = ResEmoteNet()
37 model.to('cuda')
38 # Print the number of parameters
39 total_params = sum(p.numel() for p in model.parameters())
```

```

40 print(f'{total_params:,} total parameters.')
41
42 import os
43 from torch.utils.data import DataLoader, random_split
44 from torchvision import datasets, transforms
45
46 def load_data(base_dir, batch_size=16, transform=None):
47     """
48         Function to load train and test datasets and return their DataLoaders.
49
50     Args:
51         base_dir (str): Base directory containing train/test subdirectories.
52         batch_size (int): Batch size for the DataLoader.
53         transform (callable, optional): Transformations to apply to the images.
54
55     Returns:
56         tuple: Train DataLoader, Validation DataLoader
57     """
58
59     # Define train and test directories
60     train_dir = os.path.join(base_dir, "train")
61     val_dir = os.path.join(base_dir, "test")
62
63     # Use torchvision.datasets.ImageFolder to automatically handle class folders
64     train_dataset = datasets.ImageFolder(root=train_dir, transform=transform)
65     test_dataset = datasets.ImageFolder(root=val_dir, transform=transform)
66
67     label_names = train_dataset.classes
68
69     # Split train_dataset into training and validation sets
70     val_size = 1533
71     train_size = len(train_dataset) - val_size
72     train_subset, val_subset = random_split(train_dataset, [train_size, val_size])
73
74     # DataLoaders
75     train_loader = DataLoader(train_subset, batch_size=batch_size, shuffle=True)
76     val_loader = DataLoader(val_subset, batch_size=batch_size, shuffle=False)
77     test_loader = DataLoader(test_dataset, batch_size=batch_size, shuffle=False)
78
79     # Print dataset sizes
80     print(f"Number of images in train loader: {len(train_loader.dataset)}")
81     print(f"Number of images in val loader: {len(val_loader.dataset)}")
82     print(f"Number of images in test loader: {len(test_loader.dataset)}")
83
84     return train_loader, test_loader, val_loader, label_names

```

```

85
86
87 # Load data
88 base_dir = "/workspace/RAF-DB"
89 train_loader, test_loader, val_loader, label_names = load_data(base_dir=base_dir,
90   batch_size=16, transform=transform)
91
92 # Inspect a batch
93 train_images, train_labels = next(iter(train_loader))
94 print(f"Train batch: Images shape {train_images.shape}, Labels shape {train_labels.
95   shape}")
96
97 test_images, test_labels = next(iter(test_loader))
98 print(f"Train batch: Images shape {test_images.shape}, Labels shape {test_labels.
99   shape}")
100
101 Number of images in train loader: 12273
102 Number of images in val loader: 1533
103 Number of images in test loader: 1533
104 Train batch: Images shape torch.Size([16, 3, 64, 64]), Labels shape torch.Size([16])
105 Train batch: Images shape torch.Size([16, 3, 64, 64]), Labels shape torch.Size([16])
106
107 # Hyperparameters
108 criterion = torch.nn.CrossEntropyLoss()
109 optimizer = optim.SGD(model.parameters(), lr=0.001, momentum=0.9, weight_decay=1e-4)
110
111 patience = 15
112 best_val_acc = 0
113 patience_counter = 0
114 epoch_counter = 0
115
116 num_epochs = 100
117
118 train_losses = []
119 val_losses = []
120 train_accuracies = []
121 val_accuracies = []
122 test_losses = []
123 test_accuracies = []
124
125 # Start training
126 for epoch in range(num_epochs):
127     model.train()
128     running_loss = 0.0
129     correct = 0

```

```

127     total = 0
128
129     for data in tqdm(train_loader, desc=f"Epoch {epoch+1}/{num_epochs}"):
130         inputs, labels = data[0].to(device), data[1].to(device)
131         optimizer.zero_grad()
132         outputs = model(inputs)
133         loss = criterion(outputs, labels)
134         loss.backward()
135         optimizer.step()
136
137         running_loss += loss.item()
138         _, predicted = torch.max(outputs.data, 1)
139         total += labels.size(0)
140         correct += (predicted == labels).sum().item()
141
142         train_loss = running_loss / len(train_loader)
143         train_acc = correct / total
144         train_losses.append(train_loss)
145         train_accuracies.append(train_acc)
146
147         model.eval()
148         test_running_loss = 0.0
149         test_correct = 0
150         test_total = 0
151         with torch.no_grad():
152             for data in test_loader:
153                 inputs, labels = data[0].to(device), data[1].to(device)
154                 outputs = model(inputs)
155                 loss = criterion(outputs, labels)
156                 test_running_loss += loss.item()
157                 _, predicted = torch.max(outputs.data, 1)
158                 test_total += labels.size(0)
159                 test_correct += (predicted == labels).sum().item()
160
161         test_loss = test_running_loss / len(test_loader)
162         test_acc = test_correct / test_total
163         test_losses.append(test_loss)
164         test_accuracies.append(test_acc)
165
166         model.eval()
167         val_running_loss = 0.0
168         val_correct = 0
169         val_total = 0
170         with torch.no_grad():
171             for data in val_loader:

```

```

172         inputs, labels = data[0].to(device), data[1].to(device)
173         outputs = model(inputs)
174         loss = criterion(outputs, labels)
175         val_running_loss += loss.item()
176         _, predicted = torch.max(outputs.data, 1)
177         val_total += labels.size(0)
178         val_correct += (predicted == labels).sum().item()
179
180         val_loss = val_running_loss / len(val_loader)
181         val_acc = val_correct / val_total
182         val_losses.append(val_loss)
183         val_accuracies.append(val_acc)
184
185         print(f"Epoch {epoch+1}, Train Loss: {train_loss}, Train Accuracy: {train_acc}, Test Loss: {test_loss}, Test Accuracy: {test_acc}, Val Loss: {val_loss}, Val Accuracy: {val_acc}")
186         epoch_counter += 1
187
188         if val_acc > best_val_acc:
189             best_val_acc = val_acc
190             patience_counter = 0
191             torch.save(model.state_dict(), 'best_model_RAF-DB_1.pth')
192         else:
193             patience_counter += 1
194             print(f"No improvement in validation accuracy for {patience_counter} epochs.")
195
196         if patience_counter > patience:
197             print("Stopping early due to lack of improvement in validation accuracy.")
198             break

```

Výpis kódu 5: Python skript použitý na trenovanie modelu

Dodatok E: Zdrojový kód pre Docker

```
1 # Use CUDA 11.2 and CUDNN 8 runtime with Ubuntu 20.04 as the base image
2 FROM nvidia/cuda:11.2.2-cudnn8-runtime-ubuntu20.04
3
4 # Set environment variables for non-interactive installation and Python path
5 ENV DEBIAN_FRONTEND=noninteractive
6 ENV PYTHON_VERSION=3.9
7 ENV PATH /usr/local/cuda/bin:$PATH
8
9 # Install dependencies and set up Python 3.9 environment
10 RUN apt-get update && \
11     apt-get install -y --no-install-recommends \
12     software-properties-common && \
13     add-apt-repository ppa:deadsnakes/ppa && \
14     apt-get update && \
15     apt-get install -y --no-install-recommends \
16     build-essential \
17     curl \
18     ca-certificates \
19     python3.9 \
20     python3.9-distutils \
21     python3.9-dev \
22     python3-pip \
23     python3-setuptools \
24     python3-venv \
25     libopenblas-dev \
26     libopencv-dev \
27     && rm -rf /var/lib/apt/lists/*
28
29 # Upgrade pip and install required Python packages with specified versions
30 # Upgrade pip and install required Python packages with specified versions
31 RUN python3.9 -m pip install --upgrade pip && \
32     python3.9 -m pip install \
33     dlib==19.24.2 \
34     matplotlib==3.8.3 \
35     numpy==1.26.4 \
36     opencv_python==4.9.0.80 \
37     pandas==2.2.2 \
38     Pillow==10.3.0 \
39     retina_face==0.0.14 \
40     seaborn==0.13.2 \
```

```

41     torch==2.1.2 \
42     torchvision==0.16.2 \
43     tqdm==4.66.1 \
44     urllib3==2.2.1 \
45     jupyter
46 # Downgrade protobuf to resolve MediaPipe and TensorFlow compatibility issues
47 RUN python3.9 -m pip install protobuf==3.20.0
48
49 # Set Python 3.9 as the default Python version and link pip
50 RUN ln -sf /usr/bin/python3.9 /usr/bin/python && \
51     ln -sf /usr/bin/pip3 /usr/bin/pip
52
53 # Set the default working directory inside the container
54 WORKDIR /workspace
55
56 # Copy local files to the container's workspace directory
57 COPY .
58
59 # Expose the port for Jupyter Notebook
60 EXPOSE 8888
61
62 # Command to run Jupyter Notebook when the container starts
63 CMD ["jupyter", "notebook", "--ip=0.0.0.0", "--port=8888", "--no-browser", "--allow-root", "--NotebookApp.token=''"']

```

Výpis kódu 6: Dockerfile pre rozpoznávanie emócií

```

1 services:
2 tensorflow_gpu:
3     build: .
4     container_name: resEmoteNet
5     runtime: nvidia
6     environment:
7         - NVIDIA_VISIBLE_DEVICES=all
8         - NVIDIA_DRIVER_CAPABILITIES=compute,utility
9         - PYTHONUNBUFFERED=1
10        - CUDA_LAUNCH_BLOCKING=1 # Add this line
11    deploy:
12        resources:
13            reservations:
14                devices:
15                    - driver: nvidia
16                    count: all
17                    capabilities: [gpu]
18    volumes:
19        - .:/workspace

```

```
20      working_dir: /workspace
21      stdin_open: true
22      tty: true
23      ports:
24      - "8888:8888"
25      command: >
26          bash -c "pip install notebook &&
27          jupyter notebook --ip=0.0.0.0 --port=8888 --no-browser --allow-root"
```

Výpis kódu 7: docker-compose.yml pre systém rozpoznávania emócií

Dodatok F: Používateľský manuál

F.1 Návod na trénovanie modelu

Tento návod vás prevedie procesom trénovania modelu pre rozpoznávanie emócií pomocou Docker kontajnera a webového rozhrania.

F.1.1 Požiadavky

Na trénovanie modelu potrebujete:

- Nainštalovaný Docker (<https://docs.docker.com/get-docker/>)
- Nainštalovaný Docker Compose (<https://docs.docker.com/compose/install/>)
- Minimálne 8 GB RAM a 4 GB GPU pamäte
- Dostatočné miesto na disku (minimálne 10 GB)

F.1.2 Postup trénovania

1. Príprava projektu

```
1 git clone https://github.com/KocurMaros/master_thesis_practical  
2 cd master_thesis_practical  
3
```

2. Zostavenie Docker kontajnera

V koreňovom adresári projektu spustite:

```
1 docker-compose build  
2
```

Tento príkaz zostaví Docker kontajner podľa definícií v súboroch Dockerfile a docker-compose.yml.

3. Spustenie kontajnera

Po úspešnom zostavení spustite kontajner:

```
1 docker-compose up  
2
```

4. Prístup k webovému rozhraniu

Po spustení kontajnera otvorte webový prehliadač a prejdite na adresu:

```
1 http://localhost:5000  
2
```

5. Spustenie trénovania

Vo webovom rozhraní:

- Vyberte dataset, ktorý chcete použiť na trénovanie
- Nastavte hyperparametre (počet epoch, batch size, learning rate)
- Kliknite na tlačidlo "Spustiť trénovanie"
- Sledujte priebeh trénovania a výsledné metriky

6. Export natrénovaného modelu

Po ukončení trénovania si môžete stiahnuť natrénovaný model kliknutím na tlačidlo "Exportovať model".

F.2 Návod na testovanie s ROS2

Tento návod popisuje, ako spustiť systém rozpoznávania emócií pomocou ROS2 Humble na Ubuntu 22.04.

F.2.1 Požiadavky

Na testovanie potrebujete:

- Ubuntu 22.04 LTS
- ROS2 Humble (<https://docs.ros.org/en/humble/Installation.html>)
- Kamera kompatibilná s ROS2
- Natrénovaný model (výstup z procesu trénovania)

F.2.2 Inštalácia a zostavenie

1. Príprava ROS2 workspace

```
1 mkdir -p ~/ros2_ws/src  
2 cd ~/ros2_ws/  
3 cp -r /path/to/your/master_thesis_practical/facial_expression ~/ros2_ws/src/  
4
```

2. Zostavenie balíka

```
1 colcon build --symlink-install --packages-select  
2 emotion_recognition
```

3. Načítanie prostredia ROS2

```
1 source install/setup.bash  
2
```

F.2.3 Spustenie systému

1. Spustenie video streamu

Najprv spustite skript pre získavanie videa z kamery:

```
1 ./scripts/video_stream.sh  
2
```

2. Spustenie rozpoznávania emócií

Po spustení video streamu spustite rozpoznávanie emócií:

```
1 ./scripts/run_facial_expression.sh  
2
```

Tento skript aktivuje:

- Detekciu tváre
- Predikčný node pre rozpoznávanie emócií
- Webový server pre vizualizáciu výsledkov

3. Prístup k výsledkom

Výsledky rozpoznávania emócií sú dostupné:

- Vo webovom rozhraní: <http://localhost:8080>
- V ROS2 topicoch:

```
1 ros2 topic echo /emotion_prediction      # výsledok predikcie  
2 ros2 topic echo /face_detection        # detekované tváre  
3
```

F.2.4 Riešenie problémov

- **Problém s kamerou:** Skontrolujte, či je kamera rozpoznaná systémom pomocou príkazu `v4l2-ctl -list-devices`
- **Problém s ROS2 nodmi:** Skontrolujte stav nodov pomocou `ros2 node list`
- **Chyba predikcie:** Uistite sa, že cesta k modelu v konfiguračnom súbore je správna

F.2.5 Ukončenie systému

Na ukončenie všetkých bežiacich nodov stlačte **Ctrl+C** v termináloch, kde sú spustené skripty, alebo použite:

```
1 ros2 lifecycle set /emotion_recognition_node shutdown
```